带应用的专家系统 302 （2026） 130489

目录列表可在 ScienceDirect 获取

专家系统及应用

期刊主页：www.elsevier.com/locate/eswa

稀疏驱动辅助掩膜调控与层级动作选择

用于大规模多目标优化

Shuzhao Pang a Qingke Zhang a * Zhi-Hui Zhan b Junqing Li c Huaxiang Zhang a

中国 250358 济南东师范大学信息科学与工程学院 B 人工智能学院，南开大学，天津，邮编 300350，
中国云南师范大学中国数学学院，昆明，邮编 650500

一个 r t i c l e i n f o

一个 b s t r a c t

本文探讨了大规模稀疏多目标问题的优化挑战，这些问题的特征包括高维决策变量、异构变量界限和复杂的结构依赖关系。为解决这些问题，我们提出了一种基于自动引导向量选择进化算法（AGSEA）的改进算法，称为 SMAF，该算法集成了结构感知采样和动态引导。具体来说，结构抽样用于利用潜在变量关系，并采用固定值评估方案进行性能评估。引入了动态加权的适应度评估机制以丰富作用空间，同时根据非支配解稀疏模式的反馈，调整个体的稀疏度水平。对基准问题和四个实际应用进行了与七种最先进多目标进化算法的全面比较。结果显示，SMAF 在双目标测试场景中始终实现竞争性收敛和稳定性，比较算法在 24 个测试实例中，反向代际距离（IGD）至少提升了约 23.6%。这些结果证实了 SMAF 在高维稀疏多目标优化中的有效性和适应性。

1. 引言

近年来，随着金融建模、生物信息学和人工智能等领域的快速发展，决策者越来越需要同时优化多个相互冲突的目标（Sharma 和 Kumar（2022）。例如，构建投资组合需要在收益最大化与风险最小化之间取得平衡。因此，多目标优化（MOO）已成为优化社区的核心研究课题。He 等人（2025），Wangetal。（2023b）。

然而，尽管传统的 MOO 算法在低维问题上取得了相当成功，但随着现实应用复杂度的增加，它们往往难以扩展（Shang 等人（2025）。现代系统，如大规模生物数据集和深度学习模型，可能涉及数千个变量，这大大增加了优化难度，因为引入了多个冲突目标以及严重的计算和收敛挑战（刘和刘（2024）、田等（2024a）、吴等（2023）。

除了高维度外，稀疏性还引入了额外的复杂性层。在许多现实任务中，比如特征选择，一个很大一部分决策变量与目标无关或相关性很弱。有效识别和利用此类稀疏结构至关重要，因为这可以降低计算成本、提升可解释性并提升泛化性能（Tian 等人，2024b）。

受这些挑战的推动，大规模稀疏多目标优化问题（稀疏 LSMOPs）受到越来越多的关注，Li 等（2023）、Sun 和江（2024）、张等（2023a）。该研究方向旨在将稀疏表示技术与先进的 MOO 策略相结合，以高效解决极高维空间中的优化任务。

为解决可扩展性问题，近期一些研究探讨了迁移学习和深度强化学习，以增强算法在不同问题实例间的适应性。其中，邵等人（2024）提出的 AGSEA 算法引入了深度强化学习框架，用于引导向量选择，有助于改善稀疏 MOPs 的收敛性和多样性。

然而，AGSEA 在大规模稀疏多目标优化中仍面临若干挑战，尤其是在高维和非均匀变量空间中。单变量的评估

*通讯作者。
电子邮件地址：shuzhao.pang@stu.sdnu.edu.cn（S. Pang）、tsingke@sdnu.edu.cn（张志）、zhanapollo@163.com（Z.-H.Zhan）、lijunqing@ynnu.edu.cn（J. Li）、huaxzhang@sdnu.edu.cn（H. Zhang）。

https://doi.org/10.1016/j.eswa.2025.130489 于 2025 年 8 月 10 日收到；2025 年 11 月 5 日收到
修订版，2025 年 11 月 16 日接受

0957-4174/ © 2025 爱思唯尔有限公司保留所有权利，包括文本和数据挖掘、人工智能训练及类似技术的权利。

贡献可能受到采样值随机性的影响，这可能掩盖单个变量的真实影响，降低变量重要性估计的稳定性。此外，辅助掩模生成机制 —— 掩膜以二进制矩阵表示决策变量在进化过程中是被激活（1）还是停用（0）—— 缺乏基于优化反馈的自适应调控。这可能导致稀疏区域的探索不平衡，以及对可变稀疏区间信息的充分利用。这些限制限制了算法在实际 LSMOP 场景下完全捕捉稀疏结构和保持稳定搜索性能的能力，凸显了方法论进一步改进的必要性 Peng 和 Ishibuchi（2020）、Wang 等（2023a）、Zou 等（2023）。

基于上述分析，本文系统性地改进了 AGSEA 算法中的深度强化学习模块。具体来说，它包括构建更具表现力的状态表示，设计分层动作决策过程以实现动作空间的有效划分和动态融合，并引入由稀疏区间引导的辅助掩码调控机制。这些改进旨在提升算法在复杂稀疏多目标优化问题中的稳定性和泛化能力。本文的主要贡献总结如下：

- 提出了一种系统变量重要性评估框架，整合多层区间分层抽样与固定值对照变量评估。具体来说，每个决策变量的可行范围被划分为三个代表性子区间（低、中、高），并从每个区间中选择一个固定值 —— 通常是中点 —— 进行评估。通过一次激活一个变量，同时保持其他变量不活跃，可以隔离每个变量的个体贡献，并在受控条件下评估。这些重要性评分作为先验知识，为结构化变量分组提供参考，并指导后续优化阶段中稀疏译码结构的构建，从而确保所有变量的公平、一致且可重复的评估。
- 提出了一种动态加权融合适应度评估方法，用于在整个优化过程中动态调整均匀抽样适应度与结构化采样适应度之间的权重。结合 Softmax 动作选择策略和基于非支配前线精英解稀疏区间的辅助掩膜调节机制，该方法计算动作概率分布并自适应调整掩模稀疏度。
- 所提 SMAF 算法基于八个基准 SMOP 问题和四个实际应用进行了评估，与多个最先进的多目标进化算法进行了比较。实验结果表明，SMAF 在解决方案质量和收敛速度方面具有竞争力，在大多数情况下表现相当甚至更优。

本文其余部分的组织如下。第二部分回顾多目标优化问题的基本概念，并对现有稀疏的 LSMOP 进行调查。第 3 节详细描述了所提出的 SMAF 算法。第四部分介绍并讨论了实验结果。第 5 部分报告了分析不同成分贡献的消融研究。最后，第六部分结束了论文，并概述了未来研究的方向。

2. 相关作品

2.1. 稀疏 LSMOP 的背景

多目标优化（MOO）致力于同时优化多个冲突的目标函数，在工程设计、资源调度和系统建模中有广泛应用。Hasanzadeh 等人（2023）、He 等人（2020）、马等人（2023）。与单目标优化相比，MOO 不再寻求单一的全局最优解，而是专注于解集这反映了目标之间的权衡关系，即帕累托最优集合与其在客观空间中的映射 —— Pareto Front Verma 等人（2021）。

一个典型的多目标优化问题可以形式地定义为 显示的方程。（1），其中$x \in \mathbb{R}^D$表示决策向量，$F(x)$表示目标函数向量，目标为 m。是决策变量 Khishe 等人（2023）的可行定义域。

$$\begin{cases} minimize & F(x) = [f1(x), f2(x), ..., fm(x)]^T \\ subjectto & x \in \Omega \end{cases}$$

随着问题规模和决策变量维度显著增加，LSMOPs 受到研究者越来越多的关注（Liu 等（2024）、Xu 等（2022）、Yang 等（2021）。为解决高维空间中低搜索效率和局部最优问题的易感性，传统优化算法引入了降维、变量分组和基于搜索策略的新算法等技术，以提升收敛性能和解多样性（Tian 等（2021）、Wang 等（2020,2019）。

降维方法旨在降低优化算法的搜索维度，同时保留原始决策空间的核心信息（Tian 等人（2020a）。其中，基于深度学习和模式挖掘的技术因其在复杂高维数据表现上的强大能力而备受关注。以 MOEA/PSL Tian 等人（2020b）为例，它通过学习帕累托最优子空间，高效实现降维。该算法用一个二进制向量表示变量稀疏度模式，以及一个实值向量表示非零变量值的解。随后，它利用限制玻尔兹曼机（RBM）Fischer 和 Igel（2012）以及去噪自编码器（DAE）Xue 等（2012）分别从二进制和实值向量中提取和压缩特征，共同构造一个低维子空间。在整个演化过程中，MOEA/PSL 通过动态调整缩减子空间与原始空间之间的搜索比率，并自适应地调整模型复杂度，平衡探索与利用。

R.H.M. Coppens 等人提出了一个将多目标进化算法（MOEA）与深度强化学习（DRL）整合的框架，Li 等人（2025）用于解决多目标优化问题，Coppens 等人（2022）。在该框架下，利用 DRL 策略动态调整 MOEA 内的突变强度和概率参数，从而提升优化性能。陈海龙等人提出了 MOPDERL Tran 等人（2023）框架，这是一种两阶段多目标进化强化学习方法，专为连续机器人控制问题设计。通过结合进化算法的鲁棒性与强化学习的高效性，该框架有效应对多目标连续控制任务。需要注意的是，这些方法虽然对一般多目标优化问题有效，但缺乏处理高维稀疏决策空间的具体机制。因此，它们未被纳入与本研究中考虑的大规模稀疏多目标算法的比较。

除了利用稀疏结构，优化搜索机制对于提升大规模多目标优化算法的性能也至关重要。稀疏 EA Tian 等（2019）通过将稀疏感知的种群初始化策略与混合遗传算子整合，高效地搜索稀疏帕累托最优解。每个解由一个二元遮罩向量和一个实值决策向量组成，这两个向量共同编码稀疏性结构和决策值。变量重要性源自非支配排序，指导初始化以保留激活概率更高的关键变量。在演化过程中，掩膜向量经历分数引导二元变异以保持稀疏性，而决策向量则通过模拟的二元交叉和多项式变异演化。这种设计使 SparseEA 能够有效维护解稀疏性

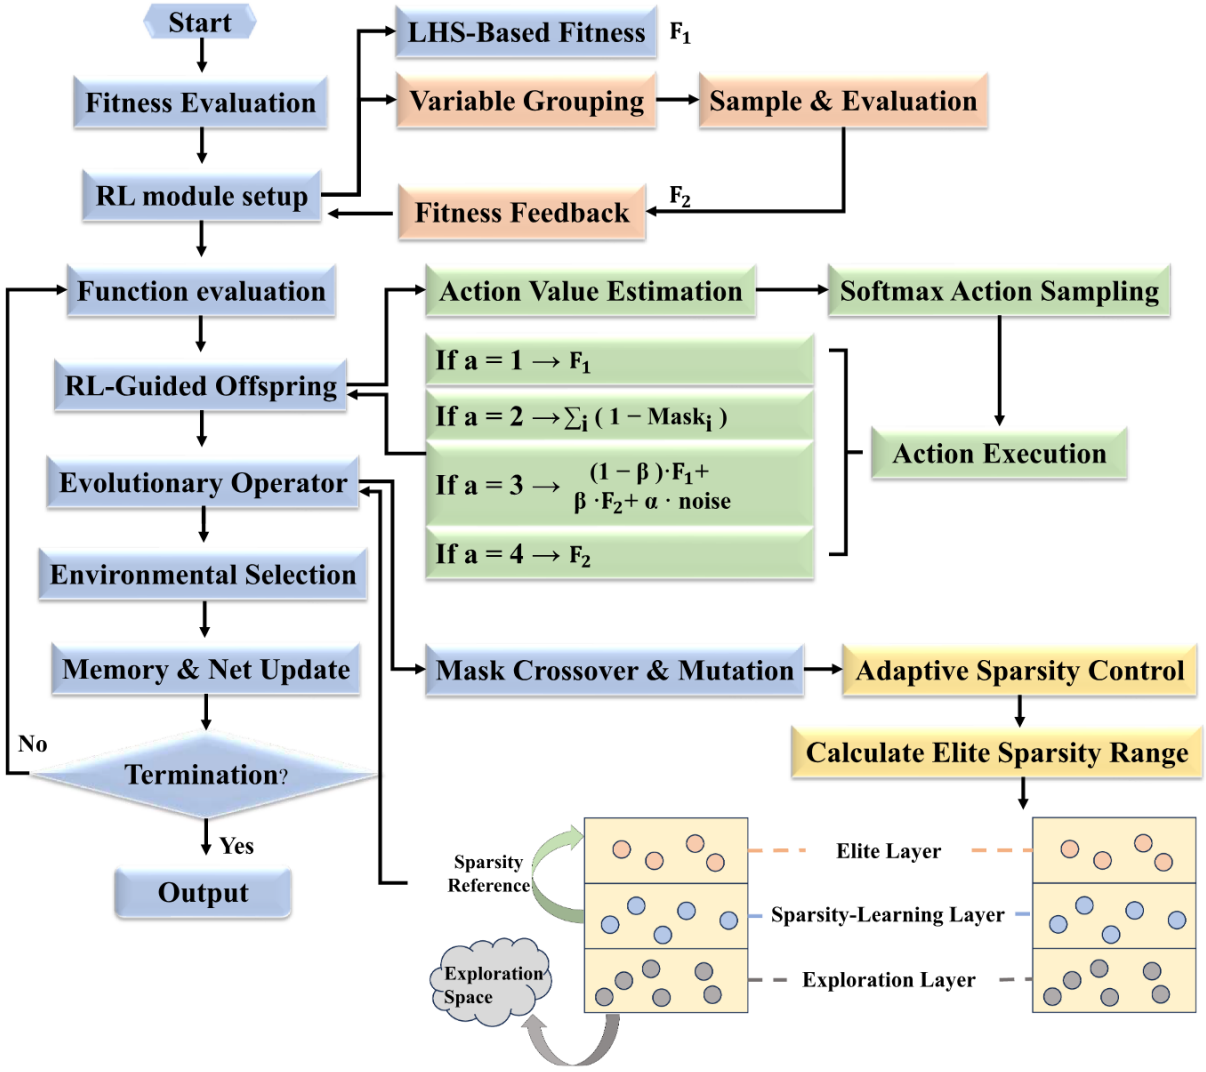


图 1。该算法的框架。

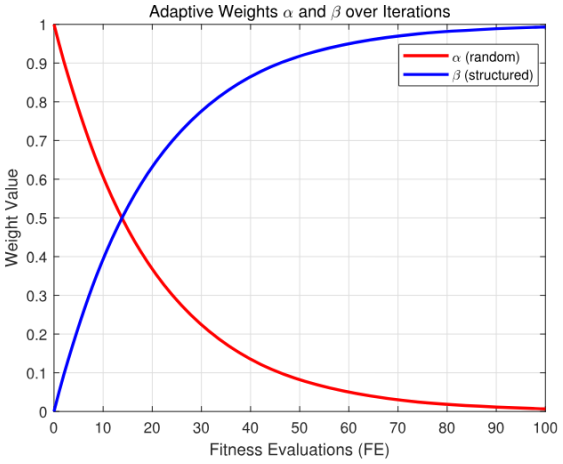


图 2。自适应权重 α （红色）和 β （蓝色）的重复，展示了从探索到开发的转变。

同时探索了多样的高质量权衡，使其非常适合大规模稀疏多目标优化问题（Ding 等人（2023））。

尽管像 SparseEA 这样的方法在建模和利用稀疏结构方面取得了显著进展，但在处理具有非均匀变量分布或动态变化稀疏度的复杂问题时，它们仍面临挑战（Zhang 等人（2024））。具体来说，这类方法往往无法及时捕捉变量重要性的变化，这既限制了得到解的多样性，也降低了收敛的效率。为此，一些近期研究尝试将强化学习机制（Raju 和 Mothku（2023）、Siraskar 等（2023）、Zhao 等（2023）整合到稀疏多目标优化中，旨在实现动态学习和搜索策略的自适应控制（Chu 等（2024））。

例如，AGSEA 算法采用深度强化学习，通过将当前种群特征映射为状态，将收敛性和多样性的提升映射为奖励，并将候选引导向量映射为动作，从而自适应地选择引导向量。这一自适应策略使 AGSEA 能够有效引导稀疏 LSMOPs 的搜索流程，在各类基准测试中展现出竞争性能。

虽然 AGSEA 实现了竞争性能，但仍有进一步提升空间，例如丰富动作空间、采用更具自适应性的掩膜扰动策略等。基于这些挑战，本文提出了一种新颖的深度强化学习框架，结合稀疏感知机制和多层次行动选择策略（Tian 等，2022a）。

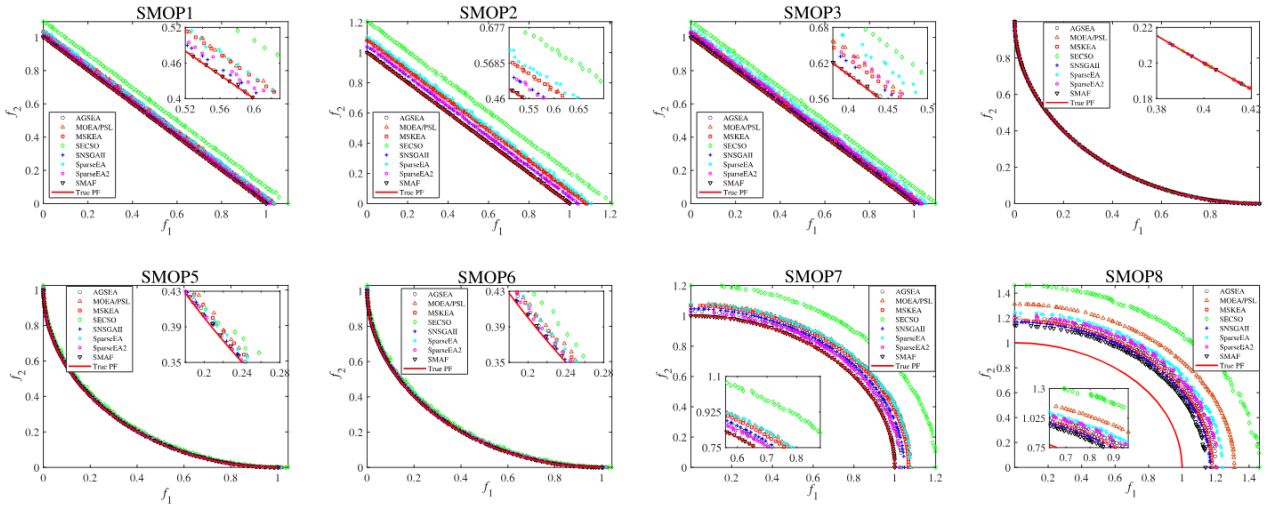


图 3。SMAF 及其竞争对手在双目标 SMOP1-SMOP8 问题中获得的中位数 IGD 的总体，该问题包含 500 个决策变量。

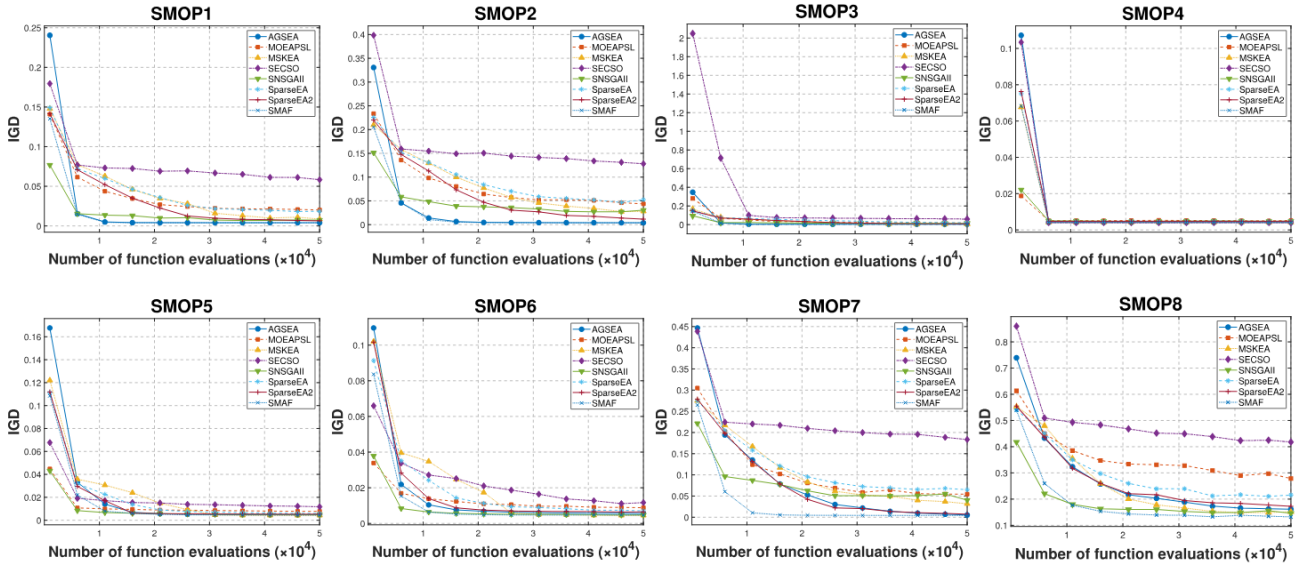


图 4。SMAF 及其比较算法在双目标 SMOP1-SMOP8 上获得的 IGD 值（中位数），在适应度评估的最大次数下，包含 500 个决策变量，范围从 1000 到 50,000 不等。

该方法通过重新设计 AGSEA 的作用建模和掩膜微扰组件系统性地扩展，目标是提升大规模稀疏多目标优化中的鲁棒性和泛化性任

2.2. 这项工作的动机

在稀疏的 LSMOP 中，传统框架如 MOEA/D、NSGA-II 变体和协作共进化方法缺乏明确机制来识别和利用变量稀疏性，因此无法有效生成高质量稀疏解。

AGSEA 通过其掩膜机制显式建模变量重要性，为稀疏优化提供了自然的基线，非常适合高维和稀疏问题。其基于掩膜的设计还促进了基于学习的增强：掩膜修改和作符选择可视为强化学习框架中的动作，而当前的种群分布、变量贡献估计和掩模稀疏性信息则可作为状态。这种结构允许动态调整搜索策略，并无缝整合新的评估方法。

在不破坏核心框架的情况下实现自适应稀疏度控制，这种灵活性是传统 MOEA/D 或 NSGA-II 所缺乏的

尽管有这些优势，AGSEA 仍存在若干局限性。首先，在评估过程中随机值可能扭曲单个变量的贡献，削弱变量重要性估计的稳定性。其次，其掩膜稀疏度控制缺乏自适应反馈，可能导致稀疏区域的探索不均匀。这些问题在高维和非均匀变量空间中尤为明显。

为克服这些限制，所提算法引入了 AGSEA 中缺乏的若干改进：（1）分层固定值控制变量评估 —— 划分决策空间并在固定条件下评估每个变量，以提供更稳定的贡献估计；（2）动态动作指导 —— 结合多源适应度信息和种群反馈，自适应地调整掩体稀疏度和操作员选择；（3）自适应稀疏度控制 —— 基于当前非显性解的反馈引导后代掩体稀疏度，改善稀疏区域的探索。

与原始 AGSEA 相比，这些改进提升了变量贡献估计的稳定性，支持自适应稀疏度调整，并利用种群反馈的动态指导，

从而加快收敛速度，并更可靠地识别稀疏解。后续实验结果验证了这些增强的有效性。

3. 提出的算法

图 1 展示了所提出的算法 SMAF 的整体框架，该算法在第 3 节中介绍。它包含了初始化、状态评估、策略更新和结果输出等关键模块，共同反映了算法的核心过程及其组件间的交互。详细的实现将在后续章节中提供。

3.1. 结构化决策空间中的固定值控制变量评估策略

在大规模稀疏多目标优化问题中，算法的收敛效率和解质量在很大程度上依赖于关键决策变量的准确识别（胡等人（2025））。在高维决策空间中，大量冗余或无效变量不仅无法对目标做出积极贡献，还可能误导搜索到低质量区域，并干扰帕累托最优子空间的识别。因此，构建能揭示决策变量重要结构的指导向量，并利用它们指导稀疏解码结构（如掩码）的生成，是一个关键问题。

AGSEA 算法采用基于统一抽样策略的评估方法，通过广泛覆盖决策空间来初始化总体。候选解通过拉丁超立方体采样（LHS）生成，McKay 等人（2000），并采用掩蔽机制评估每个决策变量在维度上的贡献。该方法的主要优势在于其计算效率和相对均匀的空间覆盖。需要注意的是，这种评估方法对应于图 1 中的成分F_1，本质上涉及一定的随机性。对于实数值的决策变量，激活值通过均匀或拉丁超立方体采样在其可行范围内生成。因此，每次运行对同一变量产生不同的采样值，导致计算的适应度向量存在差异，从而导致变量贡献在各次运行间的非确定性排序。

为解决这一问题并获得变量贡献的系统评估，采用了固定值对照变量抽样策略。具体来说，每个决策变量x_1在其可行区间$[l_i, u_i]$内进行分析，该区间被划分为$k = 3$等于子区间，以便系统地探索低、中、高区域。在每个子区间内，将一个代表性的候选值置于中点，作为受控评估的固定值。如果中点与零重合，则将其移至上界u_i，以避免无效的零值变量。

对于每个子区间，稀疏个体通过仅激活选定变量而保持其他变量不活跃来构建。随后，利用问题的目标函数和约束函数对这些个体进行评估，得出每个变量位置的初步重要性分数。通过一次激活一个变量，并将固定值与基于区间的抽样结合，该策略确保每个位置在受控且可比的条件下进行评估。这些重要性评分为后续优化阶段中稀疏解码结构的生成提供了可靠的先验知识。

决策变量 $x_i \in [l_i, u_i]$ 的第 j 个子区间的代表点是 iscomputedas（参见 Eq.（2））：

$$x_i^{(j)} = l_i + \frac{2j-1}{2k} (u_i - l_i), \quad j = 1, \ldots, k$$

其中 k 表示子区间的数量，2j-1 j 表示子区间的索引。分数 $\frac{2j-1}{2k}$ 表示 的归一化中点

)	No. of objective M	Sparsity of Pareto optimal solutions
	2, 3	0.1

)	Dataset	Length of signal	Number of observations	Sparsity of signal
	Synthetic Liang et al. (2018)	1024	480	260
	Synthetic Liang et al. (2018)	2048	960	520
	Synthetic Liang et al. (2018)	5120	2400	1300

)	Dataset	No. of samples	No. of features	No. of classes
	MUSK1[a]	476	166	2
	Semeion Handwritten Digit[a]	1593	256	10
	LSVT Voice rehabilitation[a]	126	310	2

)	Dataset	No. of nodes	No. of edges
	GD(A99)[b]	234	154
	GD(A01)[b]	311	640
	GD(C97)[b]	452	460

)	Dataset	No. of transactions	No. of items	Avg. length of variables variables transactions
	Synthetic Agrawal and Srikant (1994)	10 000	500	50
	Synthetic Agrawal and Srikant (1994)	10 000	1000	50
	Synthetic Agrawal and Srikant (1994)	10 000	2000	50

表 1 八个基准 SMOP 和四个实用 SMOP 的参数设置。A http://archive.ics.uci.edu/ml/index.php B

表 2 SMAF 及其比较算法在 SMOP1-SMOP8 双目标基准问题中获得的 IGD 结果的平均和标准差，每行中最佳结果被高亮显示。“+”、“-” 和 “≈” 表示另一家 MOEA 的结果优于、不如或与 SMAF 相当。

Problem	D	MSKEA	S-NSGA-II	SparseEA	SparseEA2	AGSEA	S-ECSO	MOEA/PSL	SMAF
SMOP1	500	2.5564e-2 (4.72e-3) -	1.0869e-2 (3.49e-3) -	2.9223e-2 (3.80e-3) -	1.6024e-2 (3.12e-3) -	4.0921e-3 (9.71e-5) -	6.9429e-2 (2.26e-3) -	2.7206e-2 (4.60e-3) -	**3.9603e-3 (7.05e-5)**
	1000	3.4014e-2 (3.13e-3) -	1.2511e-2 (2.86e-3) -	3.5485e-2 (2.83e-3) -	2.0996e-2 (2.60e-3) -	4.2370e-3 (1.40e-4) -	7.0136e-2 (2.11e-3) -	3.3493e-2 (9.74e-3) -	**4.0478e-3 (6.56e-5)**
	2000	3.8447e-2 (2.68e-3) -	1.6893e-2 (3.82e-3) -	4.1871e-2 (2.19e-3) -	3.2381e-2 (2.52e-3) -	4.3553e-3 (1.51e-4) -	7.0891e-2 (1.08e-3) -	3.7313e-2 (3.61e-3) -	**4.0468e-3 (5.73e-5)**
SMOP2	500	6.2370e-2 (7.91e-3) -	3.3632e-2 (1.09e-2) -	7.6209e-2 (6.92e-3) -	3.4257e-2 (6.66e-3) -	5.0688e-3 (1.70e-3) -	1.4503e-1 (3.58e-3) -	6.0752e-2 (8.00e-3) -	**4.2087e-3 (1.20e-4)**
	1000	7.8099e-2 (6.71e-3) -	5.3309e-2 (1.09e-2) -	8.4786e-2 (5.11e-3) -	4.6753e-2 (4.38e-3) -	5.3630e-3 (1.45e-3) -	1.4807e-1 (3.27e-3) -	6.9187e-2 (7.92e-3) -	**4.4260e-3 (1.29e-4)**
	2000	9.0240e-2 (4.51e-3) -	7.1114e-2 (1.59e-2) -	1.0177e-1 (4.21e-3) -	7.0163e-2 (4.06e-3) -	5.3317e-3 (1.45e-3) -	1.4951e-1 (2.62e-3) -	8.1528e-2 (5.58e-3) -	**4.3656e-3 (1.17e-4)**
SMOP3	500	1.9820e-2 (5.95e-3) -	1.6175e-2 (4.37e-3) -	4.2830e-2 (4.85e-3) -	2.6199e-2 (3.46e-3) -	**4.0174e-3 (2.70e-4)** =	6.9548e-2 (2.60e-3) -	8.5146e-2 (3.11e-1) -	4.0475e-3 (2.52e-4)
	1000	2.7764e-2 (3.52e-3) -	1.9990e-2 (4.20e-3) -	4.7183e-2 (2.70e-3) -	3.2661e-2 (3.41e-3) -	4.0654e-3 (2.77e-4) =	6.9736e-2 (1.80e-3) -	2.9069e-2 (2.52e-3) -	**3.9679e-3 (6.99e-5)**
	2000	3.1913e-2 (2.50e-3) -	2.3802e-2 (4.31e-3) -	5.2630e-2 (2.31e-3) -	4.0633e-2 (2.78e-3) -	4.6204e-3 (1.85e-3) -	7.0506e-2 (1.10e-3) -	3.8596e-2 (5.38e-3) -	**3.9668e-3 (8.76e-5)**
SMOP4	500	4.1370e-3 (5.48e-5) =	4.9182e-3 (2.86e-4) -	4.7385e-3 (2.32e-4) -	4.8676e-3 (2.38e-4) -	4.1406e-3 (8.35e-5) =	**3.9657e-3 (7.47e-5)** +	5.1152e-3 (4.66e-4) -	4.1267e-3 (5.18e-5)
	1000	4.1052e-3 (7.70e-5) =	4.7913e-3 (2.46e-4) -	4.7104e-3 (2.01e-4) -	4.7747e-3 (2.01e-4) -	4.1257e-3 (5.67e-5) =	**3.9616e-3 (7.02e-5)** +	5.1441e-3 (3.09e-4) -	4.1348e-3 (7.80e-5)
	2000	4.1303e-3 (7.18e-5) =	4.7822e-3 (2.82e-4) -	4.7542e-3 (2.08e-4) -	4.7249e-3 (1.96e-4) -	4.1389e-3 (6.58e-5) =	**3.9979e-3 (6.29e-5)** +	5.1933e-3 (3.49e-4) -	4.1250e-3 (6.79e-5)
SMOP5	500	8.8386e-3 (2.98e-3) -	5.4407e-3 (2.70e-4) -	7.9201e-3 (4.70e-4) -	5.6114e-3 (2.11e-4) -	5.3985e-3 (3.68e-4) -	1.3887e-2 (9.91e-4) -	8.8889e-3 (6.24e-4) -	**4.7723e-3 (1.76e-4)**
	1000	1.2147e-2 (3.13e-3) -	5.7365e-3 (1.16e-3) -	7.6816e-3 (4.61e-4) -	5.2968e-3 (2.12e-4) -	4.9631e-3 (1.93e-4) -	1.3165e-2 (1.19e-3) -	9.5585e-3 (4.37e-4) -	**4.6126e-3 (1.32e-4)**
	2000	1.3555e-2 (1.64e-3) -	8.8114e-3 (3.01e-3) -	7.9176e-3 (4.30e-4) -	5.1992e-3 (2.55e-4) -	4.8177e-3 (1.81e-4) -	1.2762e-2 (1.39e-3) -	9.5759e-3 (4.75e-4) -	**4.5341e-3 (9.53e-5)**
SMOP6	500	9.8824e-3 (3.95e-3) -	5.2066e-3 (2.32e-4) -	9.8844e-3 (9.14e-4) -	7.1508e-3 (4.95e-4) -	6.5200e-3 (6.14e-4) -	1.7335e-2 (2.99e-3) -	1.0773e-2 (6.07e-4) -	**4.7780e-3 (1.97e-4)**
	1000	1.4097e-2 (2.94e-3) -	5.2451e-3 (3.05e-4) -	9.7180e-3 (7.17e-4) -	7.0328e-3 (3.41e-4) -	5.9915e-3 (3.32e-4) -	1.6304e-2 (3.77e-3) -	1.2653e-2 (1.20e-3) -	**4.6740e-3 (1.79e-4)**
	2000	1.6583e-2 (1.64e-3) -	5.4371e-3 (3.84e-4) -	1.0261e-2 (6.00e-4) -	6.9669e-3 (2.83e-4) -	5.9466e-3 (2.85e-4) -	1.6655e-2 (3.63e-3) -	1.3370e-2 (5.25e-4) -	**4.6853e-3 (1.51e-4)**
SMOP7	500	6.8955e-2 (1.07e-2) -	5.3537e-2 (1.49e-2) -	8.1179e-2 (1.05e-2) -	3.1083e-2 (6.85e-3) -	3.5130e-2 (9.30e-3) -	2.0447e-1 (6.68e-3) -	1.4150e-1 (1.29e-1) -	**4.5377e-3 (5.10e-4)**
	1000	8.6415e-2 (8.05e-3) -	7.8087e-2 (1.79e-2) -	1.0084e-1 (5.44e-3) -	3.6089e-2 (5.32e-3) -	5.4255e-2 (1.02e-2) -	2.0984e-1 (4.18e-3) -	1.8971e-1 (1.28e-1) -	**4.6113e-3 (3.80e-4)**
	2000	1.0552e-1 (7.06e-3) -	1.1830e-1 (2.52e-2) -	1.2307e-1 (4.89e-3) -	6.3768e-2 (3.79e-3) -	8.7954e-2 (1.14e-2) -	2.0961e-1 (3.86e-3) -	1.7068e-1 (1.10e-1) -	**4.5134e-3 (1.02e-4)**
SMOP8	500	1.8001e-1 (1.70e-2) -	1.6709e-1 (1.90e-2) -	2.4183e-1 (1.77e-2) -	2.1527e-1 (1.38e-2) -	2.0678e-1 (1.66e-2) -	4.6213e-1 (7.88e-3) -	3.1891e-1 (3.51e-2) -	**1.4219e-1 (9.10e-3)**
	1000	2.1920e-1 (1.45e-2) -	1.8154e-1 (1.81e-2) -	2.7566e-1 (1.32e-2) -	2.4190e-1 (1.26e-2) -	2.2842e-1 (1.68e-2) -	4.6355e-1 (8.58e-3) -	4.2558e-1 (2.91e-2) -	**1.4521e-1 (8.28e-3)**
	2000	2.5704e-1 (1.17e-2) -	1.9990e-1 (1.47e-2) -	3.1372e-1 (1.02e-2) -	2.5257e-1 (1.21e-2) -	2.7711e-1 (1.05e-2) -	4.6474e-1 (9.33e-3) -	4.7075e-1 (1.44e-2) -	**1.4931e-1 (3.00e-3)**
+/-/=		0/21/3	0/24/0	0/24/0	0/24/0	0/19/5	3/21/0	0/24/0	

间歇。如果计算出的中点为零，可以用非零值替代，例如上界u_i，以避免产生无效的样本。

对于每个子区间 j，这些中点值被赋予相应变量，以构造稀疏个体，然后利用问题的目标函数和约束函数进行评估。通过这些评估，得出初步变量重要性评分，为后续优化提供先验知识。

与随机或非固定评估方法相比，固定值控制变量抽样策略能够系统且可靠地评估每个变量的位置。使用固定值子区间抽样一次激活一个变量，确保了受控且一致的评估。然而，在单个变量处评估每个变量时不动点可能会忽略其在整个可行区间内的行为，可能遗漏非线性效应或极端贡献。因此，通过结合分层固定值评估策略与基于区间的统一抽样评估策略，可以实现更全面、更有意义的变量重要性评估，从而平衡稳定性与覆盖性。伪代码在算法 1 中呈现。

3.2. 动作空间增强与动态聚变机制的设计

强化学习模块中的状态评估在提升大规模稀疏多目标优化的决策效率和探索效果方面起着关键作用。期间

表 3 SMAF 及其比较算法在 SMOP1-SMOP8 三目标基准问题上获得的 IGD 结果的平均差和标准差，每行中最佳结果均值被高亮显示。“+”、“-” 和 “≈” 表示另一家 MOEA 的结果优于、不如或与 SMAF 相当。

Problem	D	MSKEA	S-NSGA-II	SparseEA	SparseEA2	AGSEA	S-ECSO	MOEA/PSL	SMAF
SMOP1	500	7.0960e-2 (1.94e-3) -	6.1136e-2 (4.32e-3) -	8.9491e-2 (3.60e-3) -	8.6523e-2 (3.20e-3) -	4.6389e-2 (1.36e-3) -	7.5615e-2 (1.57e-3) -	1.0023e-1 (7.61e-3) -	**4.3185e-2 (7.83e-4)**
	1000	7.1153e-2 (1.58e-3) -	6.1671e-2 (5.29e-3) -	8.6638e-2 (3.41e-3) -	8.8153e-2 (8.84e-3) -	4.4960e-2 (1.11e-3) -	7.5494e-2 (9.80e-4) -	9.7426e-2 (3.29e-3) -	**4.2502e-2 (4.26e-4)**
	2000	7.1017e-2 (1.27e-3) -	6.4784e-2 (3.25e-3) -	8.5546e-2 (4.34e-3) -	9.0766e-2 (1.45e-2) -	4.4695e-2 (1.45e-3) -	7.5305e-2 (7.15e-4) -	9.4762e-2 (3.26e-3) -	**4.2457e-2 (4.61e-4)**
SMOP2	500	1.2229e-1 (4.29e-3) -	7.5211e-2 (6.04e-3) -	1.4663e-1 (5.43e-3) -	1.4372e-1 (4.34e-3) -	6.0431e-2 (3.21e-3) -	1.3663e-1 (3.78e-3) -	1.6326e-1 (5.00e-3) -	**5.4496e-2 (1.48e-3)**
	1000	1.2266e-1 (4.54e-3) -	8.1575e-2 (7.43e-3) -	1.4491e-1 (6.40e-3) -	1.4458e-1 (3.62e-3) -	5.9310e-2 (2.78e-3) -	1.3530e-1 (1.71e-3) -	1.6109e-1 (3.23e-3) -	**5.3650e-2 (1.81e-3)**
	2000	1.2392e-1 (2.43e-3) -	9.3810e-2 (7.17e-3) -	1.4108e-1 (4.05e-3) -	1.4469e-1 (3.50e-3) -	5.9691e-2 (2.66e-3) -	1.3573e-1 (1.84e-3) -	1.6210e-1 (4.20e-3) -	**5.4365e-2 (1.75e-3)**
SMOP3	500	6.4344e-2 (5.49e-3) -	6.0336e-2 (4.71e-3) -	9.3724e-2 (3.80e-3) -	8.8770e-2 (2.92e-3) -	4.3663e-2 (7.94e-4) -	2.9280e-1 (1.77e-1) -	1.6301e-1 (4.10e-1) -	**4.2889e-2 (6.91e-4)**
	1000	6.7176e-2 (4.73e-3) -	6.1937e-2 (2.98e-3) -	9.5585e-2 (3.50e-3) -	9.3852e-2 (3.05e-3) -	4.5348e-2 (9.80e-4) -	1.2814e-1 (5.52e-2) -	1.9006e-1 (4.06e-1) -	**4.3775e-2 (7.98e-4)**
	2000	6.6006e-2 (4.02e-3) -	6.5031e-2 (3.29e-3) -	9.5638e-2 (3.72e-3) -	9.5945e-2 (1.98e-3) -	4.7392e-2 (1.68e-3) -	1.0013e-1 (1.69e-2) -	3.4757e-1 (6.79e-1) -	**4.4024e-2 (6.24e-4)**
SMOP4	500	3.0123e-2 (5.44e-4) +	7.2845e-2 (1.43e-2) -	6.2494e-2 (8.64e-3) -	5.6423e-2 (4.44e-3) -	3.0343e-2 (3.88e-4) +	**2.9120e-2 (6.07e-4)** +	6.2626e-2 (1.71e-2) -	3.0690e-2 (6.34e-4)
	1000	3.0326e-2 (5.39e-4) =	7.2450e-2 (1.45e-2) -	6.4200e-2 (1.03e-2) -	6.0723e-2 (1.04e-2) -	3.0560e-2 (6.37e-4) =	**2.9176e-2 (6.03e-4)** +	5.8884e-2 (1.34e-2) -	3.0576e-2 (6.13e-4)
	2000	3.0178e-2 (5.37e-4) =	7.1933e-2 (1.10e-2) -	6.2982e-2 (8.72e-3) -	5.8583e-2 (7.56e-3) -	3.0379e-2 (5.63e-4) =	**2.8938e-2 (5.05e-4)** +	6.3831e-2 (1.14e-2) -	3.0392e-2 (6.92e-4)
SMOP5	500	3.7585e-2 (1.84e-3) -	7.0173e-2 (1.03e-2) -	7.0836e-2 (1.20e-2) -	6.4462e-2 (1.24e-2) -	3.4682e-2 (8.53e-4) -	3.7740e-2 (9.48e-4) -	6.0484e-2 (8.24e-3) -	**3.1921e-2 (8.41e-4)**
	1000	3.7252e-2 (1.90e-3) -	7.6403e-2 (1.50e-2) -	7.0201e-2 (1.06e-2) -	6.7360e-2 (1.12e-2) -	3.2636e-2 (1.04e-3) =	3.9262e-2 (1.20e-3) -	6.5110e-2 (8.24e-3) -	**3.2224e-2 (7.77e-4)**
	2000	3.7108e-2 (1.17e-3) -	7.9774e-2 (1.15e-2) -	7.0574e-2 (1.08e-2) -	6.9048e-2 (1.43e-2) -	3.1658e-2 (5.69e-4) -	3.8909e-2 (7.79e-4) -	6.5254e-2 (1.08e-2) -	**3.1534e-2 (7.45e-4)**
SMOP6	500	3.7419e-2 (2.73e-3) -	6.8180e-2 (7.87e-3) -	7.4515e-2 (9.11e-3) -	6.3886e-2 (5.28e-3) -	3.4011e-2 (9.42e-4) -	4.0660e-2 (1.70e-3) -	6.7624e-2 (1.21e-2) -	**3.2418e-2 (9.57e-4)**
	1000	3.7514e-2 (3.24e-3) -	7.8734e-2 (1.26e-2) -	7.3777e-2 (7.61e-3) -	6.4784e-2 (8.28e-3) -	3.2713e-2 (7.56e-4) -	4.2046e-2 (2.47e-3) -	7.8306e-2 (2.41e-2) -	**3.1497e-2 (5.89e-4)**
	2000	3.7830e-2 (2.36e-3) -	7.7440e-2 (1.06e-2) -	7.2451e-2 (8.70e-3) -	6.6192e-2 (7.58e-3) -	3.2305e-2 (6.97e-4) -	4.2288e-2 (2.36e-3) -	7.0710e-2 (1.33e-2) -	**3.1295e-2 (6.14e-4)**
SMOP7	500	1.9076e-1 (9.86e-3) -	1.0339e-1 (1.01e-2) -	2.1688e-1 (7.38e-3) -	2.1704e-1 (6.84e-3) -	1.6001e-1 (2.51e-2) -	2.3229e-1 (4.03e-3) -	2.7949e-1 (1.50e-1) -	**6.2950e-2 (1.70e-3)**
	1000	1.9620e-1 (6.33e-3) -	1.1518e-1 (1.16e-2) -	2.1844e-1 (6.61e-3) -	2.2150e-1 (5.95e-3) -	1.7870e-1 (1.79e-2) -	2.3128e-1 (3.13e-3) -	2.6669e-1 (1.02e-1) -	**6.2912e-2 (9.03e-4)**
	2000	1.9922e-1 (3.95e-3) -	1.3178e-1 (1.30e-2) -	2.1346e-1 (6.99e-3) -	2.2481e-1 (3.74e-3) -	1.9777e-1 (1.91e-2) -	2.3166e-1 (4.83e-3) -	2.5089e-1 (6.59e-2) -	**6.3584e-2 (1.31e-3)**
SMOP8	500	3.5611e-1 (2.54e-2) -	**1.9554e-1 (2.04e-2)** +	4.2841e-1 (1.71e-2) -	4.2258e-1 (2.49e-2) -	3.4624e-1 (3.05e-2) -	5.0670e-1 (3.15e-2) -	4.6669e-1 (3.22e-2) -	2.2953e-1 (1.40e-2)
	1000	3.9117e-1 (2.05e-2) -	**2.1030e-1 (1.72e-2)** =	4.4051e-1 (1.43e-2) -	4.4689e-1 (1.36e-2) -	3.7978e-1 (2.68e-2) -	5.0564e-1 (1.34e-2) -	5.2523e-1 (1.02e-2) -	2.1573e-1 (1.14e-2)
	2000	4.1165e-1 (8.32e-3) -	2.2885e-1 (1.68e-2) -	4.5237e-1 (1.01e-2) -	4.7277e-1 (9.84e-3) -	4.2907e-1 (3.21e-2) -	4.9447e-1 (1.02e-2) -	5.3621e-1 (4.13e-3) -	**2.1208e-1 (9.47e-3)**
+/-/=		1/21/2	1/22/1	0/24/0	0/24/0	1/20/3	3/21/0	0/24/0	

表 4 SMAF 及其竞争对手在实际测试问题上获得的 HV 结果的平均值和标准差。每行中最佳结果用黑色加粗突出显示。

Problem	D	S-ECSO	S-NSGA-II	SMAF
SR1	1024	1.9220e-1 (7.18e-3) -	1.1428e-1 (5.28e-3) -	**3.9470e-1 (1.75e-3)**
SR2	2048	1.9123e-1 (8.07e-3) -	1.0207e-1 (3.22e-3) -	**3.7882e-1 (1.37e-3)**
SR3	5120	1.7507e-1 (6.12e-3) -	9.5257e-2 (1.35e-3) -	**3.7088e-1 (1.39e-3)**
+/-/=		0/3/0	0/3/0	

表 5 SMAF 及其竞争对手在实际测试题中获得的 HV 结果的平均值和标准差。每行中最佳结果用黑色加粗突出显示。

Problem	D	AGSEA	MSKEA	SparseEA	SparseEA2	MOEAPSL	SMAF
SR1	1024	3.8804e-1 (2.92e-3) -	3.4182e-1 (6.78e-3) -	3.8957e-1 (3.25e-3) -	3.8914e-1 (4.46e-3) -	3.0790e-1 (1.69e-2) -	**3.9470e-1 (1.75e-3)**
SR2	2048	3.6878e-1 (2.66e-3) -	3.0871e-1 (6.74e-3) -	3.7280e-1 (3.86e-3) -	3.7336e-1 (3.99e-3) -	2.8760e-1 (1.16e-2) -	**3.7882e-1 (1.37e-3)**
SR3	5120	3.5887e-1 (1.37e-3) -	2.9182e-1 (4.17e-3) -	3.6922e-1 (2.95e-3) -	3.6908e-1 (2.69e-3) -	2.4159e-1 (5.01e-3) -	**3.7088e-1 (1.39e-3)**
FS1	166	9.8235e-1 (7.46e-3) -	9.6831e-1 (8.83e-3) -	9.8033e-1 (8.28e-3) -	9.6941e-1 (8.75e-3) -	9.8119e-1 (4.54e-3) -	**9.8681e-1 (4.65e-3)**
FS2	256	9.2596e-1 (5.49e-3) -	9.1736e-1 (4.75e-3) -	9.2423e-1 (4.62e-3) -	9.2098e-1 (5.04e-3) -	9.2774e-1 (4.10e-3) -	**9.3206e-1 (5.67e-3)**
FS3	310	9.9826e-1 (2.33e-4) =	9.9228e-1 (1.36e-2) =	9.9585e-1 (9.06e-3) =	9.8492e-1 (1.75e-2) -	9.9811e-1 (1.15e-3) =	**9.9829e-1 (2.50e-4)**
CN1	234	9.7335e-1 (5.16e-4) -	9.7354e-1 (6.35e-4) -	9.7296e-1 (4.29e-4) -	9.7193e-1 (8.25e-4) -	9.6973e-1 (1.17e-2) -	**9.7462e-1 (4.61e-4)**
CN2	311	9.2083e-1 (2.58e-3) -	9.2464e-1 (2.76e-3) -	9.2038e-1 (2.28e-3) -	9.1401e-1 (4.18e-3) -	9.2283e-1 (3.23e-3) -	**9.2945e-1 (1.88e-3)**
CN3	452	9.9621e-1 (1.56e-5) -	9.9620e-1 (1.85e-5) -	9.9621e-1 (9.08e-6) -	9.9610e-1 (6.61e-5) -	9.9435e-1 (4.62e-3) -	**9.9622e-1 (1.51e-6)**
PM1	500	1.9975e-1 (4.49e-3) -	1.9768e-1 (4.46e-3) -	2.0429e-1 (3.18e-3) =	1.7176e-1 (3.95e-3) -	1.6294e-1 (6.39e-2) -	**2.0574e-1 (3.66e-3)**
PM2	1000	1.9108e-1 (3.99e-3) -	1.9194e-1 (4.57e-3) -	2.0094e-1 (4.55e-3) =	1.7082e-1 (3.03e-3) -	1.3621e-1 (8.41e-2) -	**2.0246e-1 (4.48e-3)**
PM3	2000	1.7509e-1 (2.50e-3) -	1.8024e-1 (4.37e-3) -	1.8980e-1 (5.26e-3) =	1.5814e-1 (3.68e-3) -	1.2895e-1 (8.07e-2) -	**1.9164e-1 (3.91e-3)**
+/-/=		0/11/1	0/11/1	0/8/4	0/11/0	0/11/1	

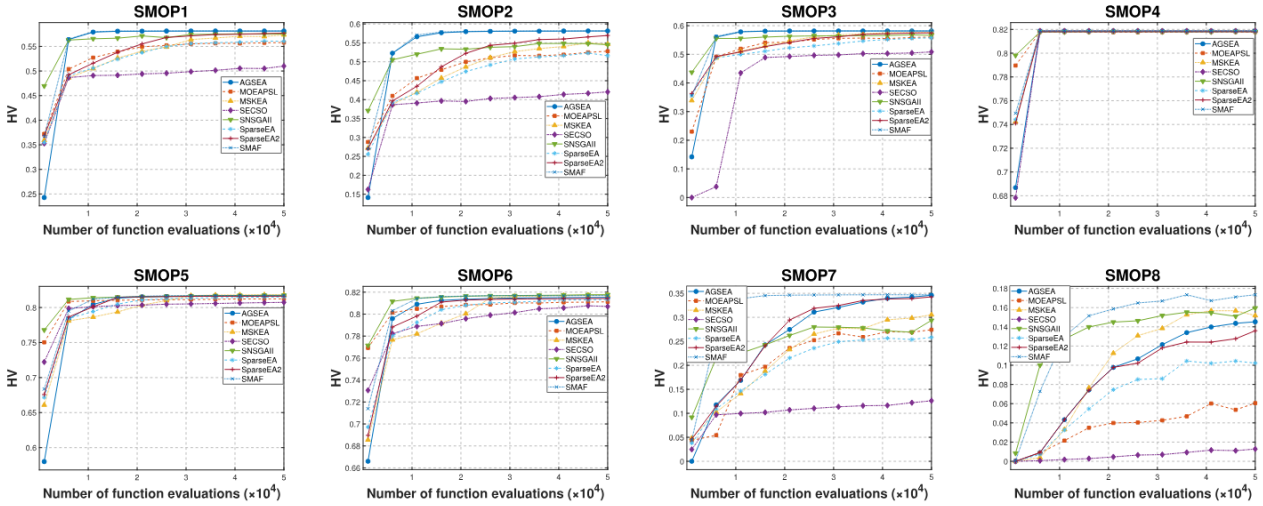


图 5。SMAF 及其比较算法在双目标 SMOP1-SMOP8 上获得的 HV 值（中位数），其中 500 个决策变量，适应度评估次数最大数从 1000 到 50,000 不等。

行动设计，准确评估当前解决方案的潜力，引导政策网络朝着更有前景的搜索方向发展。

在 AGSEA 算法中，动作设计与适应度评估机制紧密结合，适应度评估机制大致可分为三类：（1）直接使用个体现有的适应度值；（2）基于变量掩模信息计算适应度以反映变量选择状态；以及（3）通过随机扰动生成适应度以促进搜索多样性。

在高维且非均匀的决策空间中，基于拉丁超立方体均匀采样的单变量微扰评估在评估单个贡献时常常存在多变量干扰，难以可靠揭示复变量 - 目标关系。为解决这一限制，我们引入了基于固定值控制的结构化评估动作。这一行动是系统的

识别变量空间的内部结构，获得可靠的先验重要性信息，并指导后续稀疏掩罩结构的生成，从而提升对关键变量的敏感性并提高搜索效率。

此外，基于随机微扰的评估由于其随机性和对结构特性的敏感性有限，可能会波动。为提升稳定性和适应性，引入了动态加权融合策略，以自适应地结合互补的适应度评估来源。具体来说，算法考虑三种互补的适应度评估动作，详见下文：

- $\mathbf{F}_0$：固定值变量评估的适应度，
- ε：一个随机噪声矢量以保持探索。

Algorithm 1: Hierarchical Structured Evaluation Strategy.

Input: N (population size), D (number of decision variables),K (number of intervals)
Output: Dec (decision matrix), $Mask$ (mask matrix)

```
// Group variables by bounds
Group variables by bounds into result;
index ← the set of unique group IDs in result;
Divide decision space into three equal intervals;
for j ← 1 to K do
    for i ← 1 to length(index) do
        // Calculate lower and upper bounds of the
           j-th subinterval
        l1 ← lower bound of the j-th subinterval of variable
          index(i);
        u1 ← upper bound of the j-th subinterval of variable
          index(i);
        m1 ← midpoint between l1 and u1;
        // Prevent degenerate or invalid values
        if m1 == 0 then
            m1 ← u1;
        Dec ← Generate the corresponding decision variable
          matrix;
        Mask ← Generate an identity matrix;
        Evaluate the masked decision variables;
        f1 ← Fitness cumulative ranking value;
return Dec, Mask, f1
```

这里，框架图中的F_1和F_2 in theframeworkdiagram（图 1）与上述定义一致。

其中，第三种作用仅依赖随机扰动，虽然这有助于维持多样性，但可能引入过度波动和对决策变量空间结构特性的响应不足。为解决这一限制，引入了动态加权融合策略，自适应地整合不同的适应度信息来源。融合适应度定义如下（见方程（3））：

$$F = (1-\beta)F_1 + \beta F_2 + \alpha\varepsilon, \quad (3)$$

其中 04de76B7-52ab-4a55-B97D-EFF58270af8DA 是用于行动评估的最终适应度向量，D 是决策变量的数量，F_1表示通过均匀抽样计算决策变量获得的指导向量，强调探索；F_2 表示通过固定值抽样对决策变量进行评估获得的指导向量，该方法侧重于对每个决策变量位置的系统性评估，E 是随机噪声，以保持受控随机性。自适应系数随时间 β，并有可调节贡献，引导搜索从全球探索向局部开发。

系数$\beta \in [0,1]$控制着均匀与结构化适应度成分之间的平衡。为了逐步将评估重点从探索转向开发，β 设计以提升

$$\beta = 1 - exp\left(-\kappa \cdot \frac{FE}{maxFE}\right),$$

（ ） 其中 FE 是当前适应度评估次数，maxFE 是最大允许值，$\kappa > 0$是控制转变速度的缩放参数（经验设定 5）。

与此同时，$\alpha \in [0,1]$决定随机扰动的主题。为了鼓励早期探索并逐步降低随机性以实现收敛，α 随着迭代呈指数衰减（见方程（5））：（

$$\alpha = exp\left(-\kappa \cdot \frac{FE}{maxFE}\right). \quad (5)$$

最初，搜索以随机扰动（α 高）为主导，促进探索（见图 2）。随着体能评估数量的增加，β 逐渐增加，强调结构化评估。在衰减过程中，随机性被降低。交叉点体现了探索与开发之间的平衡。

虽然融合策略提升了适应度评估，但其有效性也取决于决定执行候选移动的动作选择策略。通过将自适应权重 β 和 合并，这种融合策略使得从均匀适度评估平滑过渡到结构化适应度。同时，保持受控随机性，以增强整个搜索过程的探索和收敛稳定性。

在最初的 AGSEA 中，动作选择遵循基于强化学习网络输出的贪婪策略。网络为每个候选动作分配优先级分数，并确定性地选择得分最高的动作（Li 等人（2024））。这一简单策略可以在低维问题或网络训练良好场景中实现快速收敛。然而，在大规模稀疏多目标优化问题中，搜索空间为高维且反馈信号稀疏或噪声较大，确定性贪婪选择可能会降低探索多样性，可能限制算法在早期学习阶段彻底探索解空间的能力。

Algorithm 2: UsingNet: Softmax-Based Action Selection.

Input: Net (neural net), Memory (experience mdemory), Fitness1, Fitness2, Fitness3, M (mask), Action, ANum (action num)
Output: Act (selected action), Fitness

```
if in early stage or Memory insufficient then
    Select a random action;
else
    CurrentState ← last entry in Memory;
    for i = 1 to ANum do
        // Combine state and action into a single
           input vector
        input ← concatenate(CurrentState, i)
        output[i] ← Net(input);
    // Apply softmax transformation
    output ← output - max(output);
    prob ← exp(output)/ ∑exp(output);
    if probabilities are invalid then
        Set prob as uniform distribution;
    Sample Action from the probability distribution prob;
switch Action do
    case 1 do
        Fitness ← Fitness1;
    case 2 do
        Fitness ← number of zero entries in M;
        if only one individual then
            Fitness ← M
    case 3 do
        β ← 1 − exp(−5 · FE/maxFE);
        α ← exp(−5 · FE/maxFE);
        Fitness ← (1 − β) · Fitness1 + β · Fitness2;
        Fitness ← Fitness + α· uniform noise;
    case 4 do
        Fitness ← Fitness2;
return Act, Fitness
```

为了解决原始贪婪动作选择策略的局限性，该策略确定性地选择网络偏好最高且可能导致过早收敛和探索不足，我们采用了基于 Softmax 的动作选择机制。该方法将神经网络产生的原始偏好值转化为概率分布，允许随机抽样动作，从而平衡探索与利用。具体来说，Softmaxfunction 将一组分数映射为z_i，概率如下（参见方程（6））：

$$p_i = \frac{exp(z_i/\tau)}{\sum_j exp(z_j/\tau)},$$

其中 τ 是控制选择随机性的温度参数。较低的 I 会让分布更清晰，有利于开发，而更高的 τ 则使其平滑，鼓励探索。

形式上，对于每个动作 a_i 的选择概率定义如下（参见方程（7））：

$$P(a_i) = \frac{e^{z_i}}{\sum_{j=1}^{|A|} e^{z_j}}, z_i = sim(net, [state, a_i])$$

这里，zi 表示神经网络在当前状态和动作 a_1 作为输入时输出的偏好分数。指数函数非线性地放大了偏好值之间的差异，增强了高分和低分动作之间的对比。归一化确保所有候选动作的概率分布有效。因此，偏好值较高的动作被选中的可能性更高，促进了有前景策略的利用，而价值较低的动作保留了非零的选择概率，保持探索性并降低陷入局部最优解的风险。伪代码在算法 2 中展示了。

3.3. 由稀疏区间反馈引导的辅助掩膜调整机制

在稀疏多目标优化中，掩膜的稀疏度水平直接影响变量选择的有效性和解的多样性 Ding 等人（2024）。过密掩膜会导致搜索空间扩大，搜索效率降低，并增加局部陷阱风险；相比之下，过于稀疏的掩码可能忽略关键变量，限制解的表现力并降低优化质量 Ding 等（2022）。因此，在保持稀疏结构的同时实现有效的搜索，已成为稀疏优化中的关键挑战。

为解决这一问题，本文提出了一种基于非主导前线精英稀疏分布的辅助控制机制。通过动态引导掩膜稀疏度趋向高质量解中观察到的典型范围，该机制提高了掩膜演化的方向性和稳定性，从而提升算法的搜索性能和收敛能力，同时保持结构简洁性。伪代码见算法 3。

在这项工作中，A-Skis 的稀疏度 S 形式上定义了活性特征的比例（见式（8））：

4e5DCCE7-c0BE-41C1-A896-ce2F1D3ABBBF7

其中 $m_i \in 0,1$ 表示第 i 个特征是否活跃，D de 表示决策变量的总数。通过汇总所有非显性个体的稀疏度值，我们得到当前最优稀疏区间 $[S_{min}, S_{max}]$

在后代生成过程中，如果后代面具的稀疏度落在该区间之外，就会触发自适应稀疏度调整机制。该机制通过调整某些位 "$_{on}$" 或 "关闭" 来调整掩膜，逐步使其稀疏度与参考区间对齐。目标稀疏度 S_{target} 确定如下（见方程（9）：

13eeee6a4-1c04-45d3-b6fc-3d76dc580d4f

Algorithm 3: Sparsity-Guided Mask Adjustment Strategy.

Input: OffMask(Offspring mask matrix), Fitness(fitness vector), problem dimension D, Population
Output: $Off Mask$

```
// Estimate sparsity range from non-dominated individuals
// Extract decision matrix
Decs_nd ← Population.decs where FrontNo = 1;
// Identify activated variables
nonMask ← Decs_nd ≠ 0;
// Compute sparsity ratios
nonS ← rowSum(nonMask)/D;
// Set sparsity bounds
S_min ← min(nonS), S_max ← max(nonS);
foreach offspring individual i do
    Compute current sparsity: s_i ← ∑(OffMask(i, :))/D;
    if s_i < S_min or s_i > S_max then
        Sample target sparsity s_i* within [S_min, S_max], optionally extended with random noise;
        if s_i > s_i* then
            Identify active variables: activeIdx ← {j | OffMask(i, j) = 1};
            Use fitness to select top or noise-perturbed variables for deactivation;
            Set OffMask(i, selected) ← 0;
        else
            Identify inactive variables: inactiveIdx ← {j | OffMask(i, j) = 0};
            Use fitness to select bottom or noise-perturbed variables for activation;
            Set OffMask(i, selected) ← 1;
return Off Mask
```

其中$r1 \in [0,1]$ isarandomnumber 用于维持多样性。此外，引入了小的扰动概率以扩展搜索范围（见式（10））：

$$S_{target} = \begin{cases} max\left(S_{min} - r2 \cdot 0.1, 0\right), & withprobabilityp \\ min\left(S_{max} + r2 \cdot 0.1, 1\right), & otherwise. \end{cases}$$

其中 $r2 \in [0,1]$ 是控制扰动幅度的随机变量，$p \in [0,1]$ 是控制扰动方向的概率参数。目标稀疏率向下扩展，概率 p 向上扩展，$1-p$。该策略允许目标稀疏度在基线采样值附近适度偏离，从而扩大搜索空间，有效防止过早收敛。

为提升稀疏度控制的有效性，我们提出了一种混合变量选择策略，结合确定性排序与基于高斯扰动的随机软选择（Geng 等人，2023）。在减少活跃特征数量时，算法会识别对当前优化目标贡献最小的变量，并相应地将其停用。这种混合方法有助于保留关键特征，同时引入受控多样性。相反，激活非活跃特征时，算法会优先考虑之前可能被忽视的重要变量。指导这些决策的重要性评分通过间接分析每个变量对搜索表现的适应度影响得出。

为评估所提稀疏度调整策略的影响，对一组基准稀疏多目标优化问题进行了消融实验。结果显示收敛行为改善，解多样性增强。详细情况

比较内容见消融研究部分（见第 5 节）。

Algorithm 4: RL-Guided Evolution.

Input: P_0 (initial population), D (number of decision variables), $G_{\max}$ (max generations), $FE_{\max}$ (max function evaluations)
Output: P_{final} (optimized population)
// Randomly initialized or pre-trained weights
Initialize DQN network with weights θ ;
// Stores experience tuples
Initialize replay buffer $\mathcal{B}$;
for $t \leftarrow 1$ **to** G_{max} **do**
  // Compute population-level state
  for *each individual* $x_i \in P_t$ **do**
    $\rho_i \leftarrow$ as defined in Eq. (11);
  $s_t \leftarrow [\text{mean}(\rho_i), \text{std}(\rho_i), FE/FE_{\max}]$;
  // Softmax action selection
  $a_t \leftarrow \text{SelectAction}(s_t, \theta)$;
  $g_{a_t} \leftarrow$ Guiding vector
  // Crossover & mutation
  $O_t \leftarrow$ Offspring population;
  $P_{t+1} \leftarrow$ Environmental-Selection$(P_t \cup O_t)$
  // Compute reward
  $r_t \leftarrow$ Eq. (14);
  // Store experience
  Store (s_t, a_t, r_t, s_{t+1}) in $\mathcal{B}$;
  // Periodic DQN training
  if *Training condition met* **then**
    TrainDQN$(\mathcal{B}, \theta)$
  // Update total function evaluations
  $FE \leftarrow FE + |O_t|$
return $P_{final} \leftarrow P_{G_{max}}$

3.4. 强化学习模块

在每一代中，SMAF 中的强化学习模块与进化过程形成闭合反馈环。伪代码见算法 4。它首先通过计算每个个体的稀疏度 ρ_i（即非零决策变量的比例），然后计算总体平均值 $\bar{\rho}$，标准差为 σ_ρ，并计算消耗函数评估的比例。相关文献 $\lambda = FE/FE_{-}max$。这三种指标构成状态向量s_t，作为 DQN（深度 Q 网络）的输入（Mnih 等人（2013）。

基于该状态，模块通过自适应 ε - 贪婪探索 - 利用策略选择引导向量$a_{\rho}{}_t$，早期算法偏向探索，后期阶段偏向利用。随后，选定的引导向量用于将决策变量划分为关键和非临界子集，从而决定交叉和突变如何应用于生成后代 o_t

后代和亲代群体合并并接受环境选择，之后利用基于超量的奖励评估多目标表现的提升，并将经验存储在回放缓冲区中进行训练。网络更新会被推迟，直到积累足够的经验（占评估预算的 25%），并在后续阶段通过近期过渡和梯度下降步骤定期进行。该机制使强化学习智能体能够持续优化策略，并在整个优化过程中自适应地引导进化搜索。

这种自适应决策机制建立在 AGSEA Shao 等人（2024）中最初提出的 DQN 框架之上，该框架直接继承于 SMAF，以确保一致性和可重复性，同时无缝集成优化过程。原版 AGSEA 的实现已开源于 PlatEMO 平台，Tian 等人（2017）支持直接访问验证和可重复性。

以下内容中，我们将详细介绍强化学习模块，包括其状态表示、动作设计、奖励定义和训练策略，以阐明 SMAF 如何继承并实现 AGSEA 基于 DQN 的决策机制。

状态 (s_t) 在第 t 代，状态向量编码种群级稀疏度和搜索进度。根据 AGSEA，每个个体 32ba6884-7bcb-4375-90ad-d4617143b51 的稀疏度 8788868a-d691-4718-4718-438e4ee72b85 被计算为非零决策变量的比例（参见方程（11））：

$$\rho_i = \frac{1}{D}\sum_{j=1}^{D} 1(x_{ij} \neq 0)$$

其中 D 是决策变量的数量。总体平均值$\bar{\rho}$和标准差σ_ρ是跨所有个体计算的，消耗功能评估的比例$\lambda = FE_t/FE_{max}$表示当前的搜索进展。这三个归一化量 $s_t = [\bar{\rho}, \sigma_\rho, \lambda]$ 构成 DQN 的输入，每个量自然都在 [0， 1] 内。在训练前，所有特征都会根据热身阶段收集的统计数据，标准化为均值和单位方差为零，以确保学习的稳定。

这一紧凑状态设计背后的理由是，$\bar{\rho}$ 反映了决策变量的全局激活水平（探索强度），σ_ρ 捕捉了种群内的结构多样性（搜索多样性），λ 则提供了优化阶段（趋同进程）的时间感知。它们共同提供了可解释且具演化意义的系统状态描述，使强化学习代理能够根据结构稀疏性和搜索动态调整决策。

引导向量：候选引导向量被明确定义为一组预定义的搜索偏好向量，记为$F = [F_1, F_2]$。每个向量编码为不同类型的先验信息，以指导进化搜索。

第一个引导向量F_1是从原始 AGSEA 算法中采纳的，作为先验知识指南。它旨在捕捉每个决策变量在优化早期阶段的重要性。具体来说，利用拉丁超立方体采样生成一组 d 个 d 维解向量，形成矩阵 R ，然后与单位矩阵 B 结合，构造测试总体 $Q = R \cdot B$。在此设置中，第 i 个解只有第 i 个变量非零（其他所有变量都设为零），从而隔离了每个变量的独立效应。随后，计算并累计每个溶液目标向量的$L1$范数，并累计为F_1的对应分量，即$F1_i \leftarrow F1_i + L1_i$。得到的向量 $F_1 = [F1_1, ..., F1_d]$反映了每个变量在客观空间中引起的扰动的大小 —— 扰动越大，变量的影响越大。由于该程序发生在实际进化过程之前，且不依赖任何适应度反馈或种群历史，F_1作为后续稀疏解搜索的基于敏感性的先验指南。

相比之下，本研究提出第二指导向量 F_2，作为基于固定值评估的结构化指导增强。对于每个变量 i，都创建一个测试解（见方程（12））。

$$m_i \odot d \tag{12}$$

其中m_i为 aunitvectorwiththethee492df-24d9-43d1-9baf-41cba1cb0971thentryequaltooneandallothers 为零，d 为所有变量预定义区间的中点值。评估每个测试解的目标函数，并累计相应的非支配秩。这会产生一个反映变量相对重要性的得分向量 —— 值越小表示在前一次测试中的表现越好。因此，F_2为指导进化搜索提供了额外的结构化先验信息，补充了原有的 F_1

动作 (a_t)：动作空间。$A = a_1, a_2, a_3, a_4$ 包含了 Offour 预定义的策略，每种策略都对应一个反映不同搜索偏好的特定指导向量。前两个指导向量，F_1 和 F_2，对应于基于敏感性和结构化先验知识，

其余动作分别引入了混合策略和稀疏聚焦策略。Eachguidingvector a_{a1} 为每个决策变量分配了相对重要性评分，表示其在交叉和突变作中的优先级。

一旦选中了a_t，对应的向量a_{a_i}用于通过 K - 手段划分将决策变量分为 “关键” 和 “非关键” 组。这些组决定哪些变量参与交叉和突变，直接将强化学习的决策与算法的变异行为联系起来。同时，每个动作也调整适应度评估：$a1$ 使用标准适应度，$a2$ 强调稀疏性，$a3$ 结合了 astochasticperbation，$a4$ 专注于基于稀疏度的评估（见方程（13））：a3 ：F3 = （1 − β） F1 + β F2 + α rand（1， D），

$$a4 : F_4 = \sum_{i=1}^{D} 1\,(x_i = 0),$$

其中$\beta = 1 - e^{-5 \cdot FE/maxFE}$在时间内平衡溶液质量和稀疏度，
$\alpha = e^{-5 \cdot FE/maxFE}$控制随着世代衰减的随机扰动强度。

通过将强化学习代理的离散行动选择映射到变量分组和适应度调制，该框架自适应地控制了稀疏度聚焦。这使得算法能够根据检测到的种群结构和当前搜索阶段，强调或放松特定变量的激活，实现探索与利用之间的动态平衡。

奖励 (r_t) 奖励功能遵循 AGSEA 的定义，衡量连续世代间超容积（HV）的改善情况（见方程（14））：

$$r_t = HV_t - HV_{t-1}. \eqno(14)$$

这种基于性能的直接信号反映了所选引导矢量在提升种群帕累托前缘近似上的有效性。

训练策略：DQN 采用与 AGSEA 相同的轻量级架构 —— 一个全连接的神经网络，拥有三层隐藏的 10 个神经元和 S 状激活功能。学习率设置为10^{-3}，折扣因子为 5cf7f39c-3169-4a63-b498-888af58e9e2。训练推迟到完成 25% 的总功能评估后，确保在学习开始前在回放缓冲区中收集到足够的过渡。之后，网络每 10 代更新一次，使用最近的 10 次跃迁，每次更新执行 100 次梯度下降迭代。与采用 ε 贪婪策略的 AGSEA 不同，SMAF 采用自适应的 Softmax 探索策略，行动概率计算为 $p(a_t|s_t) = Softmax(Q(s_t, a_t; \theta)/\tau_t)$，温度$\tau_t = 1 - \lambda$ gradu 随着搜索推进逐渐降低，实现从探索到开发的平稳过渡。

延迟训练开始（占预算的 25%）防止了对不稳定早期动态的过度拟合，并确保了多样化的回放缓冲。每 10 代更新一次可以平衡计算开销和适应速度，这一点在 AGSEA 中得到验证，并在初步消融测试中得到确认。这些选择已被证明能在不同基准问题上实现稳定收敛和有效决策适应。

强化学习模块保留了 AGSEA 的核心决策原则，并将其嵌入更广泛的 SMAF 框架中，形成了一个可解释的自适应引导向量选择过程。

3.5. SMAF 中机制的整合与协同

SMAF 算法将其关键机制集成到一个连续且协同的优化工作流程中。固定值控制变量评估（F2）为每个决策变量生成可靠的重要性评分，指导稀疏候选解的构建，并为后续融合提供先验知识。均匀采样适应度（F1）和随机噪声补充了 F2，以保持广泛的探索以及受控的随机性，防止搜索过早聚焦于有限区域。这些组成部分通过动态加权聚变与自适应系数结合，形成一个融合的适应度向量，平衡全球勘探与局部开发。

融合向量为基于 Softmax 的动作选择提供信息，Softmax 可视为轻量级强化学习（RL）决策模块。该模块概率地选择有前景的搜索方向，即哪些变量需要突变或更新，同时保持探索多样性，从而降低局部被困的风险。所选行动还通过稀疏感知调控指导，变量激活根据精英稀疏区间进行自适应控制，以保留关键变量并保持种群多样性。

通过这种紧密耦合的机制相互作用，SMAF 有效利用固定值评估、动态融合、随机动作选择、稀疏度引导调控和掩膜调整等互补优势。强化学习模块作为 “控制器” 或策略网络，根据当前状态动态选择动作，并通过环境反馈不断调整决策，确保变量优先级的有效、探索与利用的平衡、稳定收敛以及大规模稀疏多目标优化中的解决方案质量。

4. 实验结果与分析

本节在 PlatEMO Tian 等人（2017）平台上进行了一系列系统实验，以评估所提出的 SMAF 算法及其对等算法的性能。实验分为两部分：（1）八个具有稀疏特性的大规模多目标基准问题（即 SMOP Tian 等（2019）测试函数）用于全面评估算法的基本性能；（2）SMAF 进一步应用于四个现实世界问题场景 —— 稀疏信号重建问题（SR1-SR3）Liang 等（2018）、临界节点检测问题（CN1-CN3）Lalou 等（2018）、特征选择问题（FS1 - FS3）Karimi 等（2023）和模式挖掘问题（PM1-PM3）（Agrawal 和 Srikant（1994），以验证其在实际应用中的有效性和适用性。它们的稀疏性、多目标性质以及决策变量映射总结如下：

·稀疏信号重建 Liang 等（2018）：目标是从有限线性观测 aele1711-9e9e95-4393-4ec9-a29c2ee4calac 重建高维信号 $x \in \mathbb{R}^N$，其中 $A \in \mathbb{R}^{M \times N}$ 表示噪声。只有一小部分信号系数 arenon-0 $(K \ll N)$ 提供了解析决策空间。稀疏性在实际中对于降低测量成本和计算负担至关重要。目标包括：（1）最小化非零系数比例（稀疏度）；（2）最小化重建误差 $\|Ax - b\|$ 主要现实世界的约束条件：测量次数有限 $(M \ll N)$ 以及噪声的存在。SMAF 将每个决策变量直接映射到信号系数，利用其自适应掩模和演化算子来平衡稀疏性和重建准确性。

- 关键节点检测 Lalou 等人（2018）：该问题旨在识别大型网络中最关键的节点，以最大化中断或增强鲁棒性。稀疏性之所以出现，是因为只能选择极少数节点。每个决策变量都是二元的，表示是否选择了某个节点。目标包括：（1）最小化所选节点的比例，（2）最小化节点移除后网络的成对连接性。现实世界的约束包括网络连接性和对所选节点数量的预算限制。在 SMAF 中，每个变量代表一个节点，算法在评估网络连接性时自适应选择稀疏的节点子集以指导搜索。

·特征选择 Karimi 等人（2023）：任务是从高维数据集中选择部分特征以提升预测性能。稀疏性之所以出现，是因为只有少数特征是

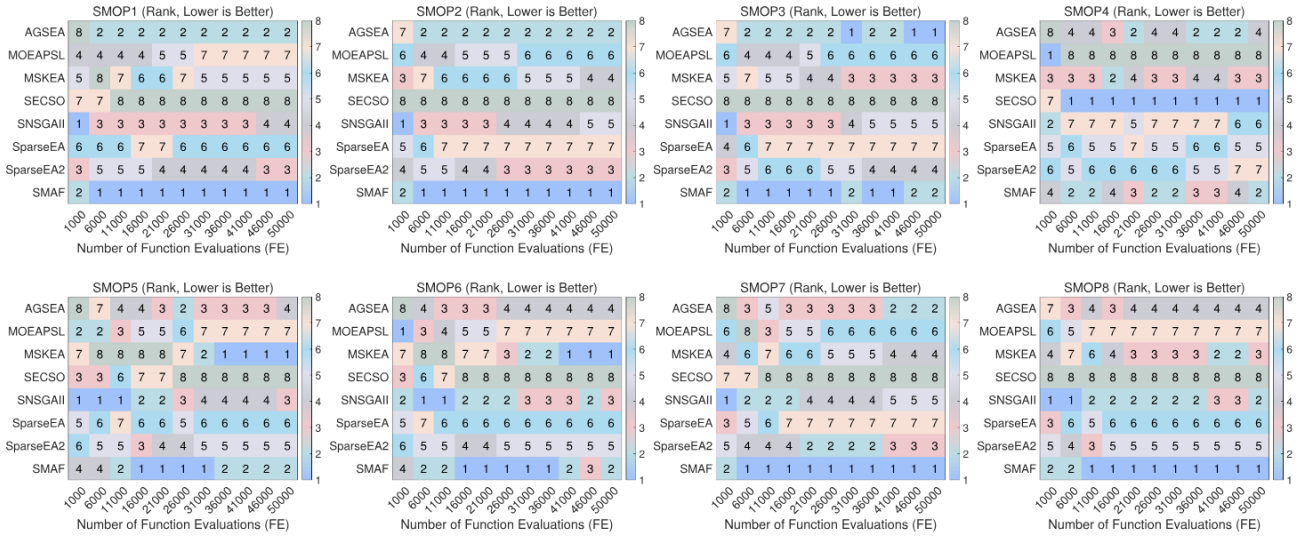


图 6。SMAF 及其比较算法在双目标 SMOP1 – SMOP8 的排名中，基于 30 次独立运行的中位数 IGD 值计算，且在不同最大适应度评估次数（1000 至 50,000 次）下计算。

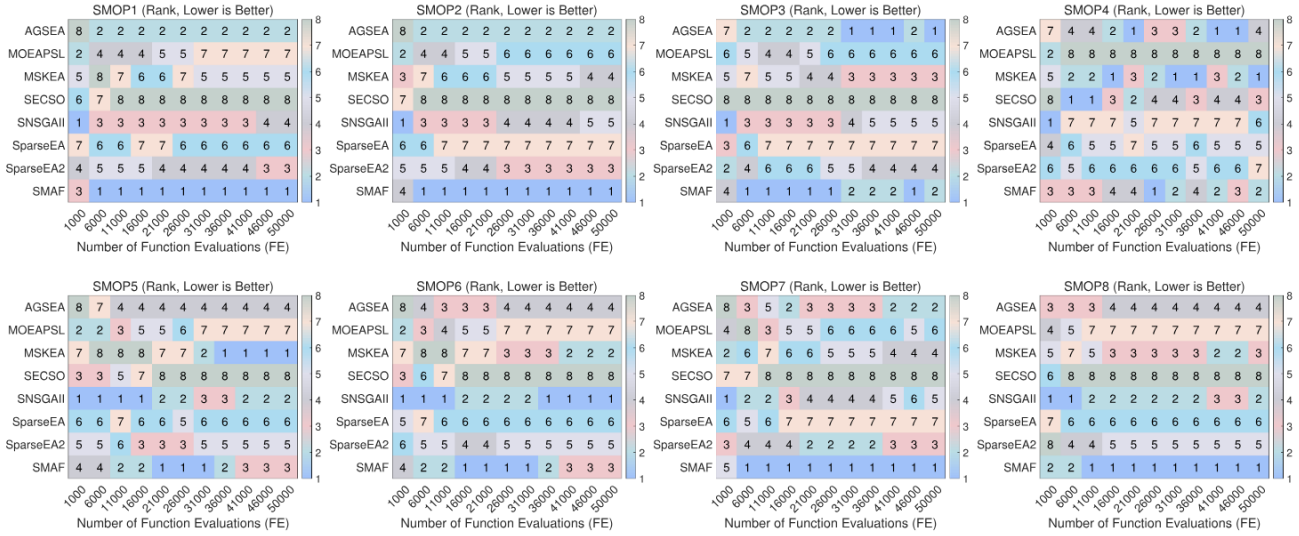


图 7。SMAF 及其比较算法在双目标 SMOP1 – SMOP8 的排名中，基于 30 次独立运行的中位 HV 值计算，适应度评估次数从 1000 到 50,000 次不等。

已选定，有助于降低模型复杂度并避免过拟合。决策变量是二元的，表示是否包含某个特征。目标包括：（1）最小化所选特征的比例，（2）最小化预测模型的验证误差。约束条件包括有限的特征预算和数据集特定的依赖关系。SMAF 应用其掩膜引导作符高效探索稀疏特征子集，同时优化预测准确性。

·模式挖掘 Agrawal 和 Srikant（1994）：任务是从大型交易数据集中识别一组常见模式。稀疏性的发生是因为所有可能的模式中只有极少部分是有意义的，这有助于降低计算复杂度并避免虚假关联。决策变量是二元的，表示是否选择了某个特定的模式。目标包括：（1）最大化所选模式对交易的覆盖，（2）最小化所选模式之间的冗余。约束包括有限的模式数量和模式特定的依赖关系。SMAF 应用其掩模引导操作员高效探索稀疏的常态子集，同时优化覆盖和冗余。在优化覆盖和冗余的同时，完成了燕鸥子集。

所有实验均在运行 MATLAB R2025a 的 Ubuntu 6.8.0-55 通用系统上进行，系统配备 Intel Xeon Silver 4214 CPU（12 核心 / 24 线程）和 30 GB 内存，支持 8 GB 交换。

4.1. 算法设置

为确保公平比较，所有算法在所有测试问题中均采用统一的 100 个总体规模。此外，每个算法在基准问题和现实问题上共执行 50×D 函数，其中 D 表示决策变量的数量。所有比较算法均采用其原始出版物推荐的参数设置实现。比较的算法包括：

比较的算法包括：

·AGSEA Shao 等（2024）：引入基于深度强化学习的自适应引导向量选择机制，结合变量聚类与稀疏感知的混合算符，以增强全局探索并保持进化方向性。

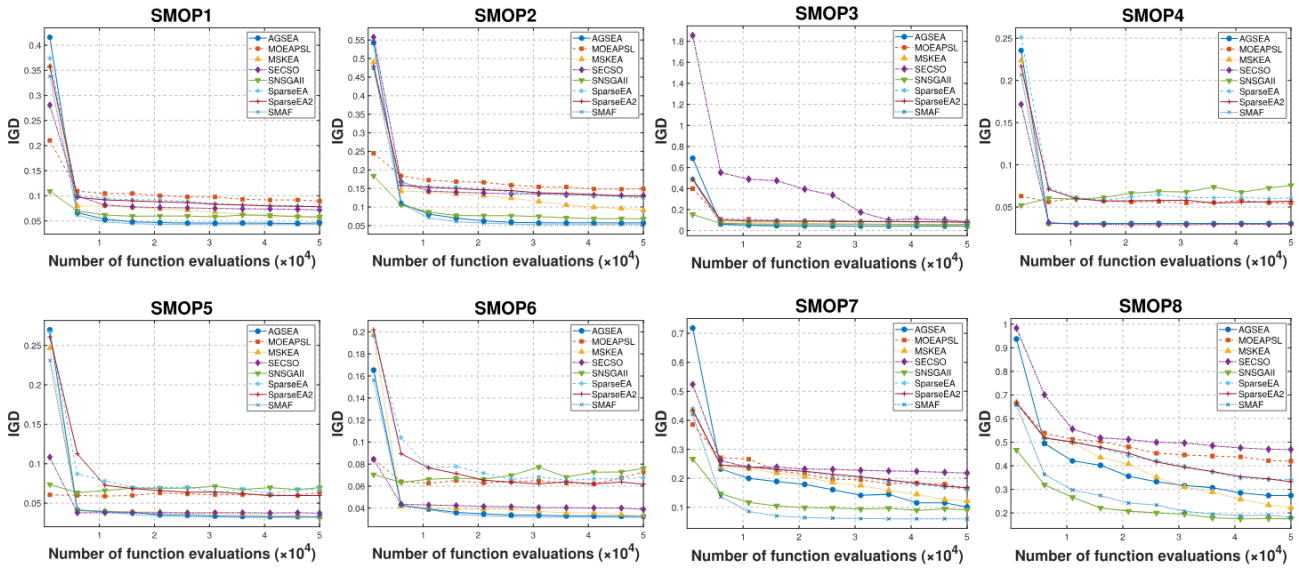


图 8。SMAF 及其比较算法在三目标 SMOP1-SMOP8 上获得的 IGD 值（中位数），包含 500 个决策变量，适应度评估最大数从 1000 到 50,000 不等。

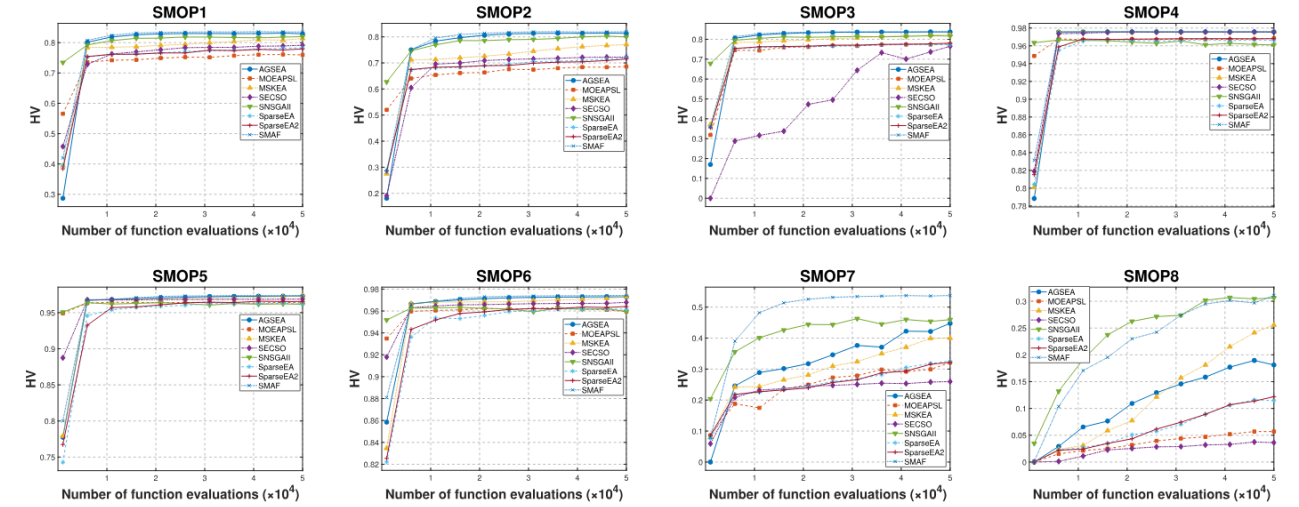


图 9。SMAF 及其比较算法在三目标 SMOP1-SMOP8 上获得的 HV 值（中位数），其中 500 个决策变量，适应度评估最大数范围为 1000 至 50,000。

·MSKEA Ding 等（2022）：采用多阶段知识引导进化框架，利用历史搜索知识指导种群进化。通过将参考点适应环境选择与稀疏感知突变结合，它有效平衡了收敛与多样性，提高了高维客观空间中的搜索效率和解质量。

·S-NSGA-II Kropp 等（2023）：通过引入可变条纹稀疏采样（VSSPS）、稀疏感知模拟二元交叉（S-SBX）和稀疏感知多项式突变（S-PM）来增强经典 NSGA-II 在大规模稀疏多目标优化中的应用。通过结构化初始种群并保持遗传作中的稀疏性，它提高了收敛速度和解稀疏度，在高维稀疏问题上优于传统的 NSGA-II 及其他稀疏优化方法。

- SparseEA Tian 等（2019）：该方法设计用于大规模稀疏多目标优化，采用基于变量评分的定向初始化和保持稀疏性的遗传算子，引导搜索向稀疏帕累托最优解方向。其核心创新关键在于使用非支配排序为决策变量分配重要性评分，指导种群初始化和突变，同时保持解稀疏性。

- SparseEA2 Zhang 等人（2023b）：引入了增强的变量分组策略和自适应稀疏性保持机制。与传统的大规模多目标优化算法相比，它更有效地识别和优化关键决策变量，展现了在高维稀疏问题上的可扩展性和收敛性。

·S-ECSO Wang 等（2021）：一种增强型竞争群体优化算法，结合三重竞争机制和差异化更新策略，以平衡探索与利用。通过引入强凸稀疏算子（SCSparse），它明确指导了稀疏帕累托最优解的生成，从而提升了在大规模稀疏多目标问题上的表现。

·MOEA/PSL Tian 等人（2020b）：利用 RBM Fischer 和 Igel（2012）及 DAE Xue 等（2012）学习稀疏帕累托最优子空间，

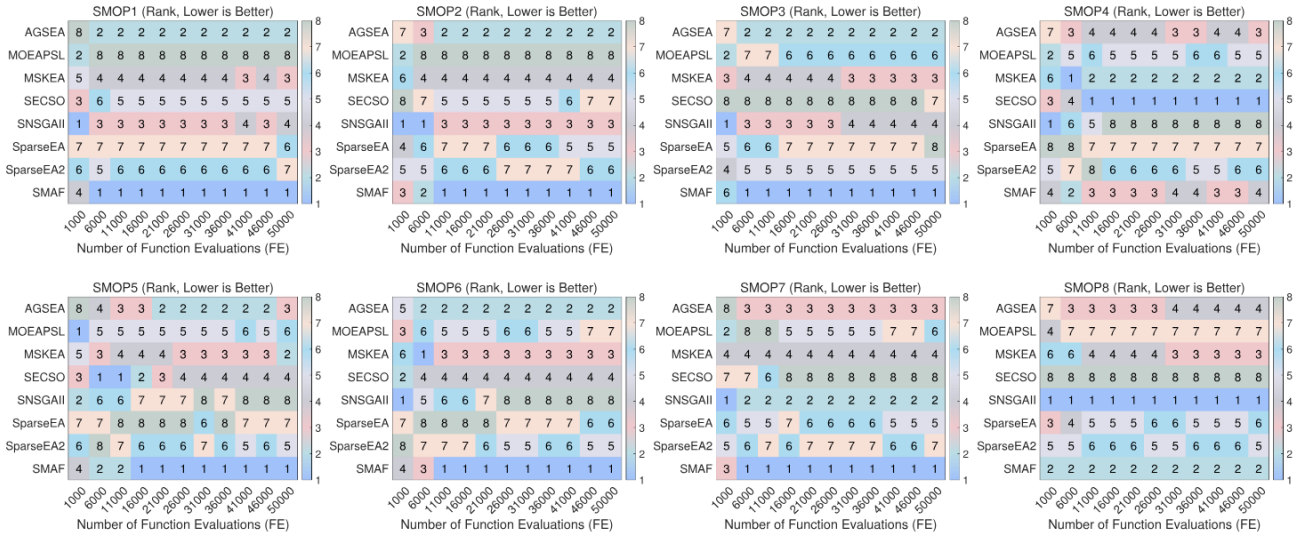


图 10。SMAF 及其比较算法在三目标 SMOP1 - SMOP8 中排名，基于 30 次独立运行的中位数 IGD 值计算，且在不同最大体能评估次数（1000 至 50,000 次）下计算。

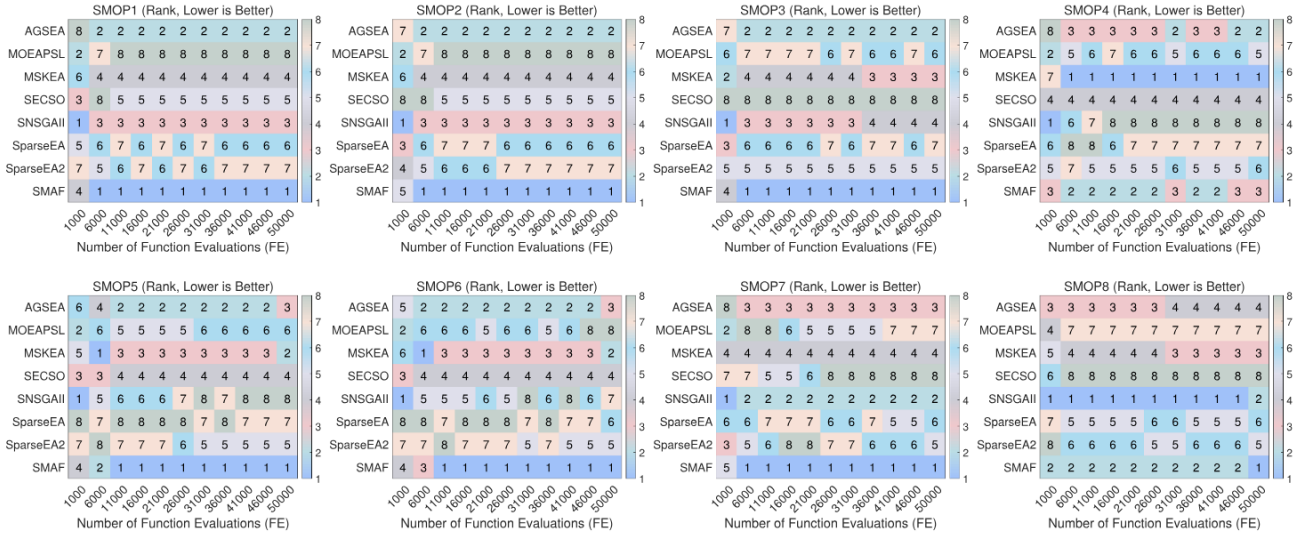


图 11。SMAF 及其比较算法在三目标 SMOP1 - SMOP8 的排名，基于 30 次独立运行的中位 HV 值计算，且在不同最大体能评估次数（1000 至 50,000 次）下计算。

在学习的低维空间中进行遗传作并进行自适应调优，提升大规模稀疏多目标问题的效率。

4.2. 问题设置

表 1 展示了基准测试问题和实际应用的详细参数设置。基准问题的决策变量（D）数量范围为 500 到 2000，实验中目标（M）设为 2 和 3。最优解的稀疏度水平统一设置为 0.1。所有测试问题的总体规模（N）始终设置为 100，以确保不同问题实例间的公平比较。为了全面评估算法在多目标优化问题上的表现，本研究采用了两种广泛使用的性能指标：反代际距离（IGD）Bosman 和 Thierens（2003）以及 Hypervolume（HV）Zitzler 和 Thiele（1999）。此外，Derrac 等人（2011）基于 30 次独立运行，针对每个测试问题进行的 Wilcoxon 秩和检验，显著性水平为 0.05，以评估性能差异的统计显著性

在所提 SMAF 与比较算法之间，符号 +、- 和≈分别表示比较算法获得的结果显著优于、显著差劣，且在统计上与拟议 SMAF 相似。

4.3. 基准问题的结果

表 2 展示了 SMAF 获得的 IGD 值统计结果及双目标基准问题 SMOP1 至 SMOP8 的比较算法。每个结果基于 30 次独立运行，决策变量维度范围为 500 到 2000。实验结果表明，SMAF 在这些问题上表现良好，效果与现有方法相当甚至更好。根据实验结果，SMAF 算法在双目标基准问题 SMOP1 - SMOP8 中表现出较强的表现，在 24 个测试实例中取得了 20 个最佳成绩。虽然在 SMOP4 上略低于 S-ECSO，但性能差距很小。此外，SMAF 通常比其他算法产生的标准差更低，表明稳定性更优。在比较算法中，只有 S-ECSO 显示

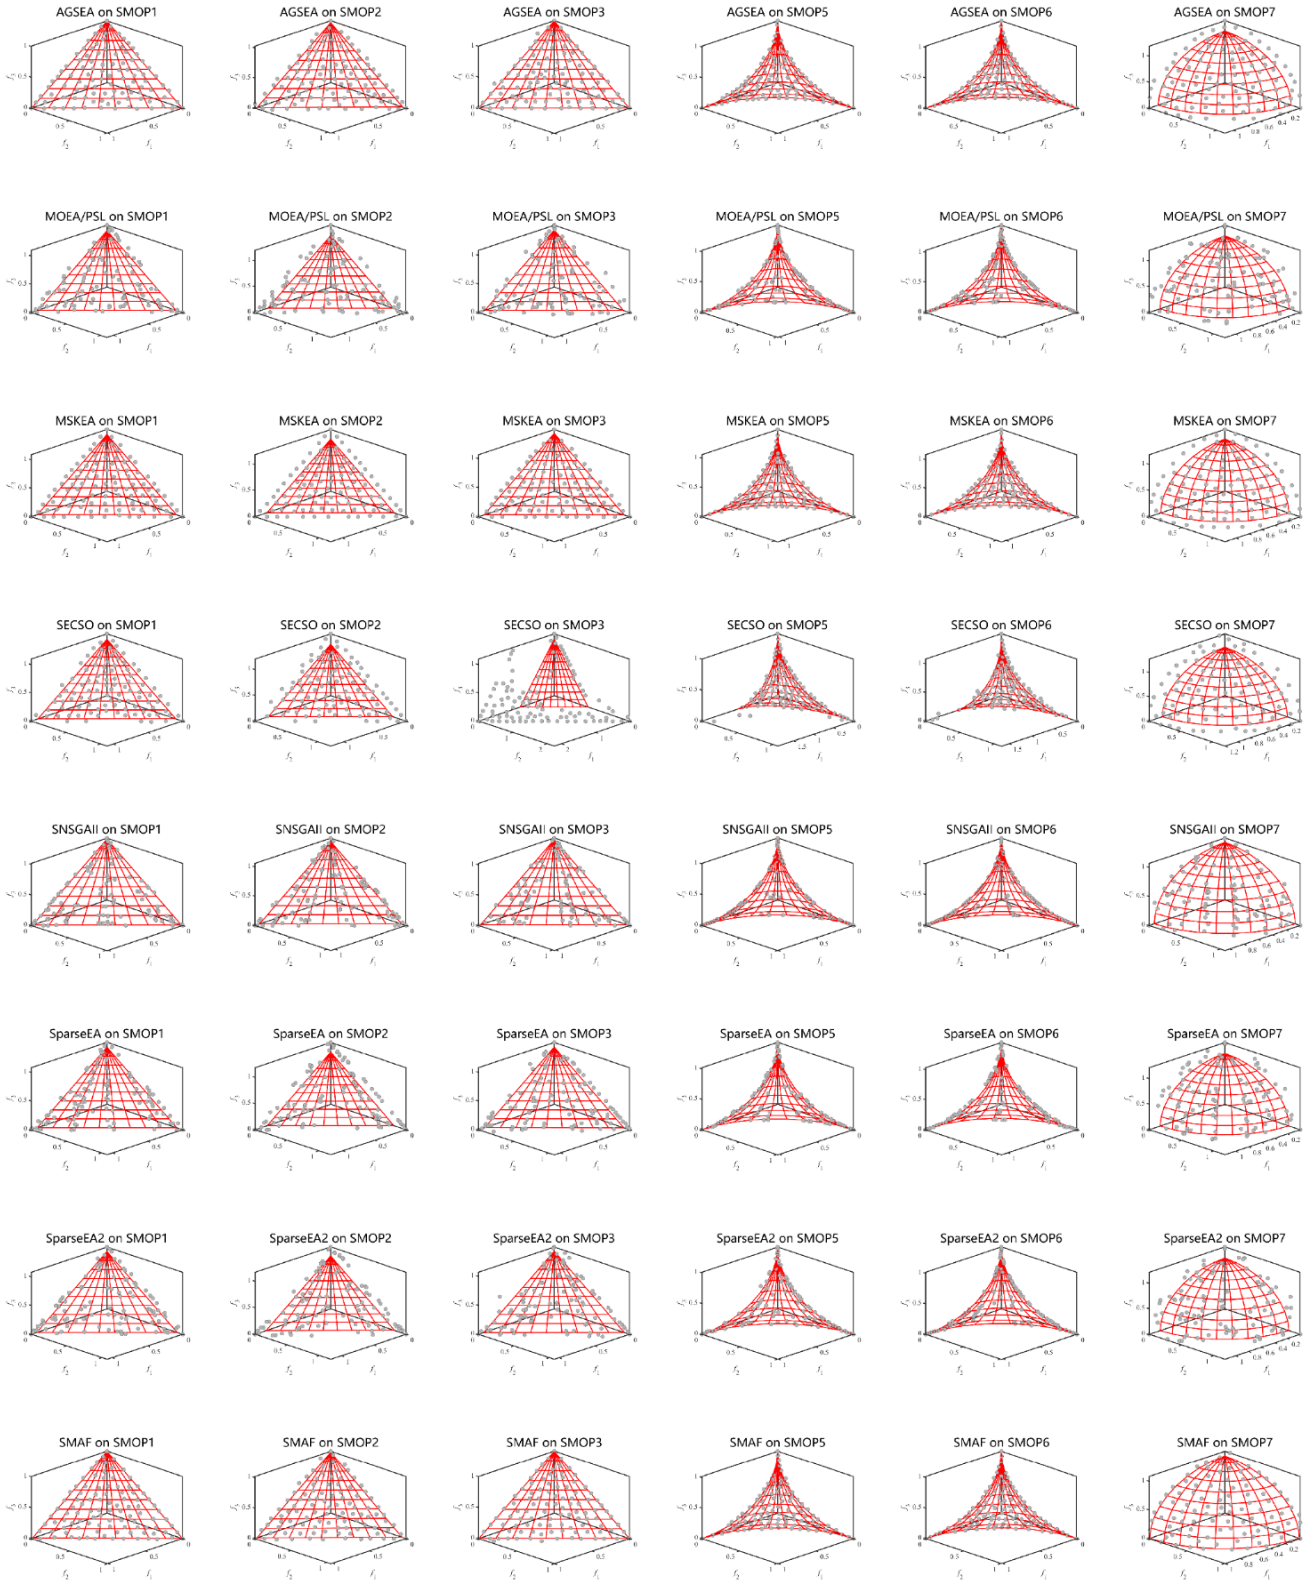


图 12。SMAF 及其竞争对手在包含 500 个决策变量的三目标 SMOP 问题中获得的中位数 IGD 的总体。

在三维中，SMOP4 的表现略好一些，而其他所有算法的表现始终不比 SMAF 好，甚至更差。此外，随着维度从 500 提升到 2000，SMAF 的平均 IGD 值依然异常稳定，恶魔

分析其对不同复杂问题的鲁棒性和适应性。

图 3 展示了 SMAF 的总体分布及对 2 目标 SMOP 测试问题的比较算法，共 500 个

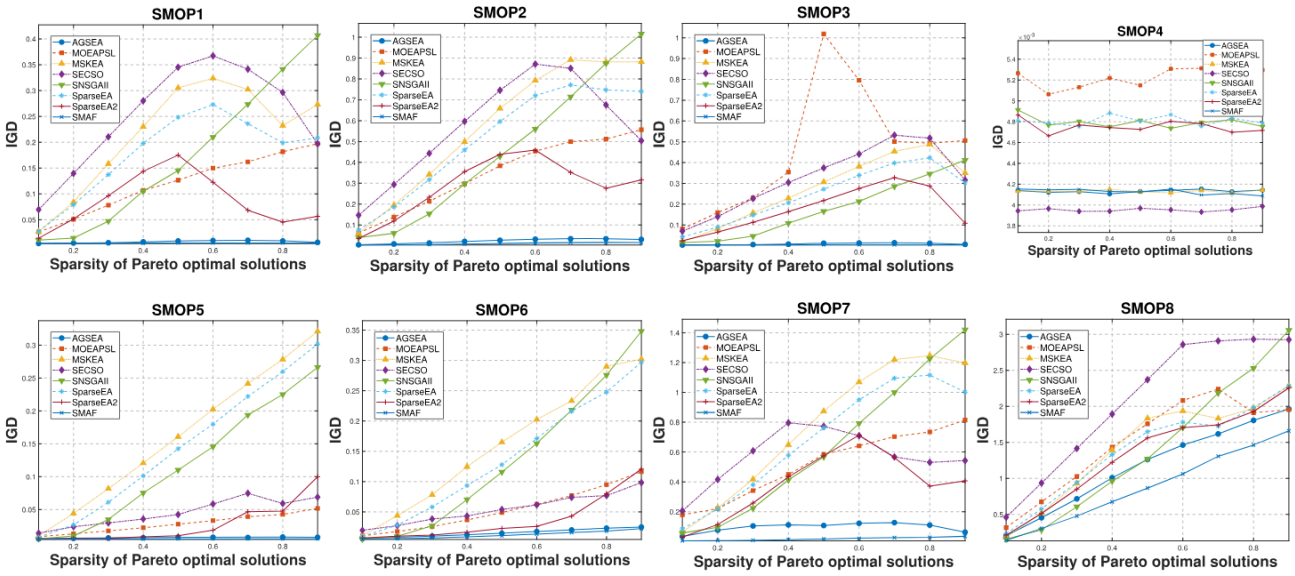


图 13。SMAF 及其四家竞争对手在 8 个 SMOP 测试问题中获得的 IGD 值，该问题包含 500 个决策变量和不同的稀疏度。

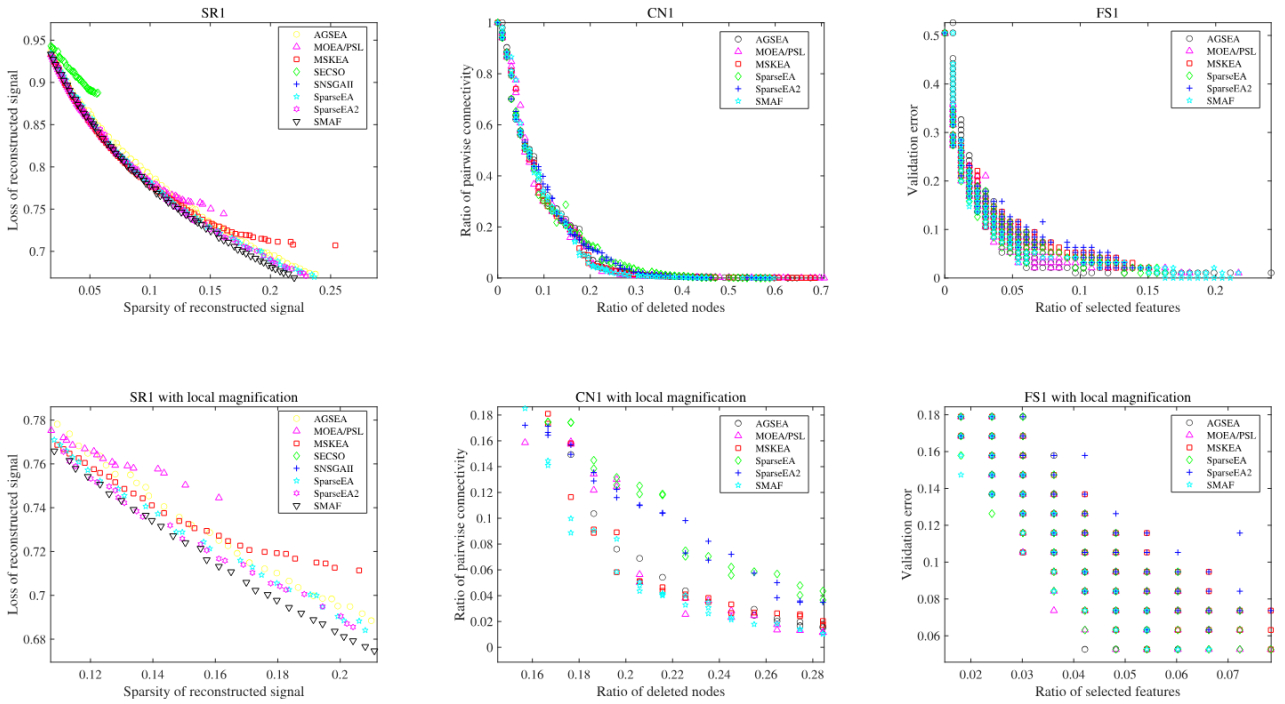


图 14。SMAF 及其竞争对手在 SR1、CN1 和 FS1 上获得的中位数 HV 的种群。

决策变量。根据表 2 的分析，SMAF 在八个测试题中有六个表现优于 AGSEA。特别是在 SMOP2、SMOP6、SMOP7 和 SMOP8 上，性能提升分别为 16.97%、26.72%、87.08% 和 31.24%。

图 4 和图 5 展示了 SMAF 获得的中位数 IGD 和 HV 值的趋势，以及在包含 500 个决策变量的双目标基准问题 SMOP1－SMOP8 的比较算法中，随着函数评估次数从 1000 个增加到 5000 个。可以观察到，SMAF 在进化早期阶段的趋同性和多样性表现较佳，这一点从 IGD 和 HV 的趋势相较 AGSEA 可见一斑。SMAF 在 SMOP7 和 SMOP8 上的表现相对突出，表明其在处理复杂稀疏优化问题时具有有效性和稳定性。对于剩余的测试问题，尽管 SMAF 仍优于 AGSEA，但性能差距相对较小，导致图中的收敛曲线几乎重叠。

因此，进一步分析应结合图 6 和图 7 以及表中的详细数值结果进行。这两个图分别基于逆代际距离（IGD）和超体积（HV）性能指标，在双目标 SMOP1－SMOP8 测试问题上评估了算法的热图排名。排名基于 30 次独立跑步中获得的中位数值，基于不同最大体能评估预算，范围从 1000 到 50,000 不等。在排名方案中，数值排名越低，算法性能越好，排名第 1 表示表现最佳的算法，其次是排名 2、3，依此类推。

总体来看，这些观察表明 SMAF 在基准问题中持续展现出竞争力的收敛性和多样性表现，凸显了其在处理复杂稀疏多目标优化任务中的稳健性。

实验结果（见表 3）表明，SMAF 算法在三目标基准问题 SMOP1－SMOP8 上总体表现具有竞争力，尤其是在 IGD 指标方面。在 24 个测试实例中，SMAF 在 19 个问题中取得了最佳成绩。尽管 S-ECSO 在 SMOP4 上略优于 SMAF，且 S-NSGA-II 在 SMOP8 的某些维度表现略优，但 SMAF 在高维度的 SMOP8 实例上仍保持优势。此外，SMAF 通常产生更小的标准差，表明结果更为稳定。具体来说，SMAF 表现为 $D = 500$ 1000 和 2000），SMOP7 显著提升超过 60%，SMOP8 则显著提升，约在 34% 至 51% 之间。相比之下，SMAF 在 SMOP4 上的性能与 AGSEA 相当。总体而言，SMAF 在大多数情况下展现出有前景的趋同和稳定性，同时部分情况下仍有进一步改进的空间。

图 8 和图 9 展示了 SMAF 在三目标基准问题 SMOP1－SMOP8 中位数 IGD 和 HV 值的中位数表现趋势，以及在函数评估次数从 1000 到 5000 次的比较算法中。如图所示，SMAF 在 SMOP1、SMOP2、SMOP6 和 SMOP7 上持续表现出优越性能。在整个优化过程中，它在 IGD 和 HV 方面都保持了明显优势。

为提供更全面的比较，图 10 和图 11 展示了基于相同中位数 IGD 和 HV 值，在 30 次独立运行中获得的算法相应热图排名。这些热图清晰展示了随着函数评估次数增加，算法的性能分布和排名动态变化。不同颜色强度凸显了在更复杂的三目标场景中，不同评估预算下的算法效能和稳定性差异。

在 SMOP8 测试问题中，尽管 S-NSGA-II 在整个评估过程中始终保持领先，但 SMAF 的性能曲线显示出稳定收敛和性能差距持续缩小。值得注意的是，评估结束时（约 5 万次评估），SMAF 的表现几乎与 S-NSGA-II 持平，显示出强大的长期潜力和稳健性。此外，SMAF 还在剩余测试问题中展现出具竞争力的适应性和收敛稳定性，进一步证明了其在处理高维三目标优化问题方面的整体优势。

图 12 展示了 SMAF 获得的总体分布及三目标测试问题 SMOP1、SMOP2、SMOP3、SMOP5、SMOP6 和 SMOP7 的比较算法，涉及 500 个决策变量。如图所示，SMAF 生成的解集在目标空间中分布更为均匀，且比其他算法更能接近真实帕累托前缘。

此外，我们还研究了 SMAF 的性能及不同稀疏度水平下 SMOP 测试函数的比较算法。图 13 展示了 SMAF 及其竞争对手在八个 SMOP 问题上获得的 IGD 结果，每个问题包含 500 个决策变量，稀疏度水平范围为 0.1 至 0.9。随着稀疏度增加，八种算法的性能通常都会下降。除了 SMOP4 问题外，SMAF 在大多数情况下仍能实现比其他比较算法更好的 IGD 性能。这展示了其在不同稀疏结构中的适应性和鲁棒性。

4.4. 现实应用结果

本节将提出的 SMAF 算法与多个同类算法在实际应用问题上进行比较。表 4 特别展示了 SMAF 在稀疏信号 re 上与两种代表性实编码算法 S-NSGA-II 和 S-ECSO 的 HV 性能

施工任务。可以观察到，SMAF 在所有测试实例中始终能获得更好的 HV 值，在每个情况下都达到最佳平均值和最小标准差。这表明 SMAF 在溶液质量和稳定性方面表现良好。在 SR2 和 SR3 等大尺度问题上，SMAF 保持领先地位，性能优势随着问题维度的增加而提升。

鉴于 S-NSGA-II 和 S-ECSO 最初是为实码优化设计的，直接应用于二进制编码问题并不被认为合适。此外，不同研究采用了不同策略来将此类算法适应二进制编码问题，但目前尚无广泛接受的标准来规范这些修改。因此，这种适应可能带来额外的变异和不确定性，使公平比较变得困难。因此，这两种算法未包含在二进制编码问题实验中。相反，专门为二进制编码问题设计或原生适用的算法作为比较基线。

表 5 展示了 SMAF 算法与多个竞争算法在实际应用场景中的性能比较。SMAF 在多个测试数据集上进行评估，包括稀疏信号重建（SR）、特征选择（FS）、关键节点检测（CN）、模式挖掘问题（PM），并且总体上与其他成熟方法相比取得了具有竞争力的成绩。对于所有 12 个实际测试问题，SMAF 都能以更小的标准差获得最佳的平均 HV 值，表明性能更优越且更稳定。与 AGSEA 相比，SMAF 在高维问题上表现更为显著（例如 SR3 提升 3.38%），而在近似最优问题（如 FS3 和 CN3）中则获得较小但一致的提升。与其他算法相比，SMAF 表现出竞争力，九个真实世界测试题的平均 HV 值通常至少与其他方法相当。从问题分类角度看，SMAF 的优势随着维度的增加而更加明显（SR 系列维度从 1024 到 5120，提升率从 1.56% 提升到 3.38%）。在中维问题（FS 和 CN 级数）及近似最优场景中，SMAF 在所有维度问题中表现相对稳定，表明其在多种优化环境中的可靠性。

在 PM 系列实验中，我们评估了具有不同决策变量维度的稀疏多目标优化问题的算法。随着维度从 500 增加到 2000，所有算法的性能都有变化。SMAF 在这三个问题上始终取得最佳或接近最佳的结果，展现了稳定的性能。SparseEA 在所有情况下都获得了与 SMAF 相当的结果，显示出一定的竞争力水平。AGSEA、MSKEA 和 MOEAPSL 的表现略逊于 SMAF。总体而言，SMAF 在处理高维稀疏多目标优化问题方面表现出强的稳定性和适应性。

图 14 展示了 SMAF 及其竞争对手在 SR1、CN1 和 FS1 上获得的中位 HV 值的种群分布。具体来说，SMAF 在 SR1 问题上比 MSKEA 提高了约 15.3%，在 FS1 问题上比 AGSEA 提高了约 0.45%。此外，SMAF 在其他测试问题上的表现通常与竞争对手算法相当或略好，大多数改进幅度在 0.1% 到 1.5% 之间，显示出收敛和多样性表现相对稳定。

4.5. 与其他基于 DRL 的优化器的比较

为了进一步验证所提 SMAF 框架的有效性，它与多个代表性的深度强化学习（DRL）基础多目标优化器进行了比较，针对一系列稀疏基准问题。比较的算法包括 DRLOSEMCMO Ming 等（2024）和 MOEA/D-DQN Tian 等（2022b），它们代表了不同的强化学习范式，如 actor－critic 和基于价值的框架。

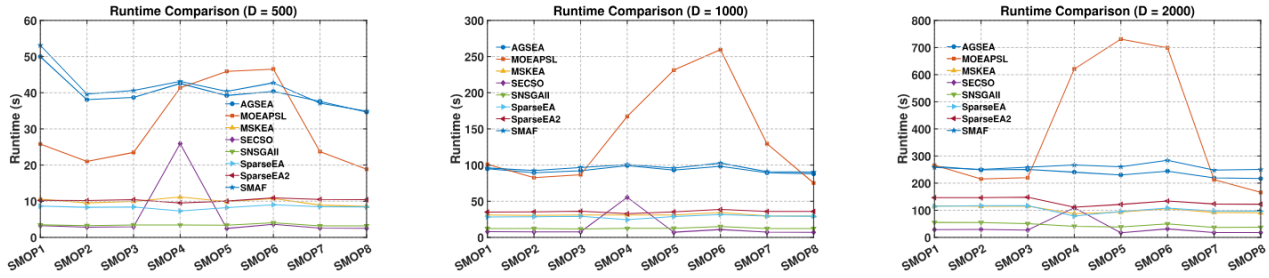


图 15. 不同算法的运行时比较。$D = 500$ 1000, 2000。

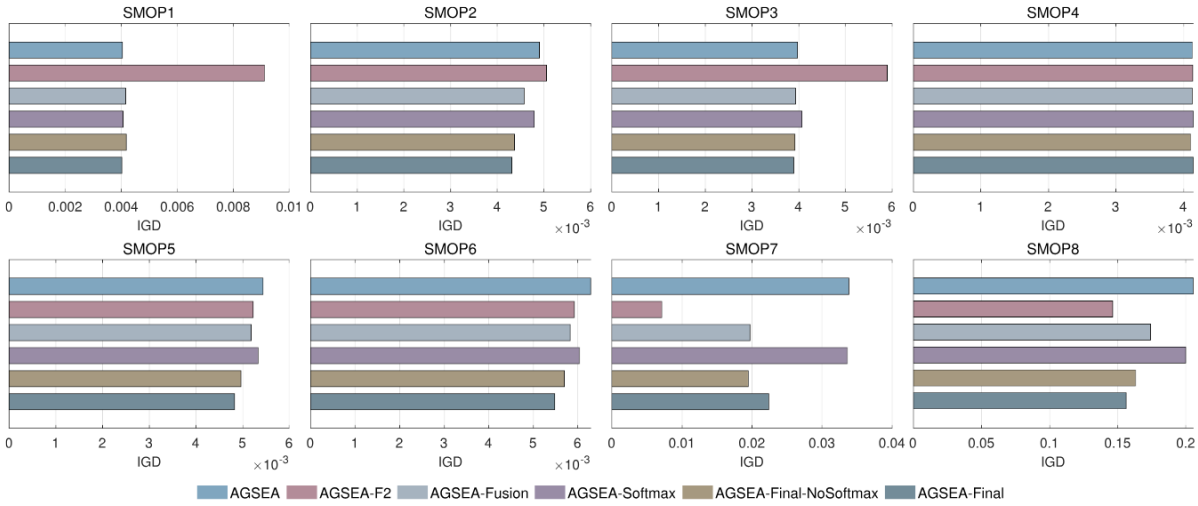


图 16。AGSEA 及其变体在双目标 SMOP1-SMOP8 上的 IGD 表现，包含 500 个决策变量。

MOEA/D-DQN Tian 等人（2022b）和 DRLOS-EMCMO Ming 等人（2024）是两种代表性的基于 DRL 的多目标进化算法，将强化学习融入优化过程。MOEA/D-DQN 采用基于价值的深度 Q 网络（DQN），在 MOEA/D 框架内自适应地选择子问题或变分算子，从而改善探索与利用之间的平衡。而 DRLOS-EMCMO 则采用 DQN 驱动的操作员选择策略，实现受限多目标优化。它维护经验池以存储状态、动作和奖励信息，实现了在演化过程中对操作员效能的自适应学习。

为了确保在稀疏条件下的公平比较，这两种算法都加入了 SparseEA 的稀疏处理机制。由此产生的改进版本，如 DRLOS-EMCMO_Sparse 和 MOEA/DDQN_Sparse，旨在更好地处理大规模稀疏多目标优化问题。所有算法都采用相同的参数设置和停止标准进行测试，性能通过反向代际距离（IGD）指标进行评估。双目标 SMOP 测试问题的统计结果总结于表 7，而三目标 SMOP 测试问题的结果则见表 8。这些结果共同展示了该算法在不同目标数量问题上的表现。

由于 DRLOS-EMCMO 和 MOEA/D-DQN 最初并非为大规模优化设计，因此测试了额外的$D = 512$实例以评估其性能，而 SMOP 测试问题仅在$D = 1000$

表 9 总结了算法在 SR 问题上的 HV 度量表现。可以观察到，SMAF 在所有维度上始终稳定地获得最高的高压值（$(D = 512, 1024, 2048)$），标准差相对较小，表明性能稳定。具体来说，是针对$D = 512$，SMAF im

在 DRLOS-EMCMO 上证明高约 9%，较 MOEA/D-DQN 高约 7.6%。相比之下，DRLOS-EMCMO 及其稀疏变体表现出较低的 HV 值，且随着问题维度的增加，这些值进一步下降，表明在高维环境中的搜索能力有限。MOEA/D-DQN 变体达到中间高压值，表明强化学习制导有一定提升，但仍不及 SMAF。总体而言，SMAF 在 SR 问题上展现出在有效性和鲁棒性方面的明显优势。

实验结果表明，在 SMOP1 – SMOP8 双目标问题中，SMAF 在大多数实例中获得最低的 IGD 值，唯独 SMOP4 和 SMOP5 中 MOEA/D-DQN_Sparse 表现略佳。在三目标问题上，SMAF 在所有情况下都取得了最佳的免疫指数（IGD）。相比之下，原始的 MOEA/D-DQN 和 DRLOS-EMCMO 算法始终表现出更高的 IGD 值，尽管稀疏性策略的引入提升了其性能，但仍未能超越 SMAF。随着目标数量的增加，其他算法的性能会明显下降，而 SMAF 则保持了强大的稳定性和鲁棒性，展现了其在大规模稀疏多目标优化中的明显优势。

4.6. 计算复杂性

SMAF 的计算复杂度主要取决于问题维度 D、种群规模 N 以及世代数 T。在初始化阶段，混合策略（FitnessCal 和 RealInit1）由于适应度估计和种群构建，需要$O(D^2 + ND)$。在每一代中，主要的计算成本来自：（1）环境选择 $O(N^2)$，（2）进化算符（包括面罩调整、交叉和突变）$O(ND)$，（3）后代的适应度评估 $O(ND)$。因此，

表 6 由 AGSEA、AGSEA-F2、AGSEA-Fusion、AGSEA-Softmax、AGSEA-Final-NoSoftmax 和 AGSEA-Final 在双目标 SMOP1 - SMOP8 上获得的 IGD 值，涵盖 500 个决策变量。每行中最佳结果都会被高亮显示。

Problem	D	AGSEA	AGSEA-F2	AGSEA-Fusion	AGSEA-Softmax	AGSEA-Final- NoSoftmax	AGSEA-Final
SMOP1	500	4.0410e-3 (7.05e-5) =	9.1104e-3 (5.57e-3) -	4.1551e-3 (2.46e-4) -	4.0717e-3 (1.58e-4) =	4.1830e-3 (3.82e-4) -	**4.0140e-3 (7.22e-5)**
SMOP2	500	4.9007e-3 (1.34e-3) -	5.0518e-3 (1.40e-3) -	4.5711e-3 (4.94e-4) -	4.7904e-3 (8.58e-4) -	4.3654e-3 (3.74e-4) =	**4.3092e-3 (3.81e-4)**
SMOP3	500	3.9762e-3 (2.46e-4) -	5.8974e-3 (7.82e-3) -	3.9315e-3 (5.23e-5) -	4.0724e-3 (4.19e-4) -	3.9230e-3 (1.46e-4) =	**3.8958e-3 (9.35e-5)**
SMOP4	500	4.1312e-3 (6.86e-5) =	4.1347e-3 (6.23e-5) =	4.1294e-3 (7.84e-5) =	4.1462e-3 (8.78e-5) =	**4.1033e-3 (7.46e-5)** +	4.1302e-3 (6.93e-5)
SMOP5	500	5.4374e-3 (3.02e-4) -	5.2276e-3 (2.78e-4) -	5.1850e-3 (3.51e-4) -	5.3289e-3 (2.67e-4) -	4.9624e-3 (2.14e-4) -	**4.8317e-3 (2.22e-4)**
SMOP6	500	6.2892e-3 (4.55e-4) -	5.9204e-3 (2.87e-4) -	5.8315e-3 (3.63e-4) -	6.0344e-3 (4.75e-4) -	5.6992e-3 (2.83e-4) -	**5.4836e-3 (2.26e-4)**
SMOP7	500	3.3834e-2 (8.22e-3) -	**7.0904e-3 (5.50e-3)** =	1.9696e-2 (1.89e-2) =	3.3588e-2 (9.53e-3) -	1.9437e-2 (2.65e-2) =	2.2368e-2 (2.76e-2)
SMOP8	500	2.0552e-1 (1.45e-2) -	**1.4642e-1 (1.18e-2)** =	1.7398e-1 (3.96e-2) -	1.9993e-1 (1.50e-2) -	1.6300e-1 (3.82e-2) =	1.5613e-1 (3.22e-2)
+/-/=		0/6/2	0/5/3	0/6/2	0/6/2	1/3/4	

表 7 SMAF 及其比较算法在 SMOP1-SMOP8 双目标基准问题上获得的 IGD 结果的平均差和标准差，每行中最佳结果被突出显示。

Problem	D	MOEA/D-DQN	MOEA/D-DQN_Sparse	DRLOS-EMCMO	DRLOS-EMCMO_Sparse	SMAF
SMOP1	1000	6.1883e-1 (4.83e-2) -	7.3862e-2 (7.56e-4) -	4.9831e-1 (2.41e-2) -	6.9838e-2 (4.47e-3) -	**4.0478e-3 (6.56e-5)**
SMOP2	1000	1.5444e+0 (1.64e-1) -	1.5683e-1 (1.12e-3) -	1.4794e+0 (4.86e-2) -	1.5273e-1 (7.69e-3) -	**4.4260e-3 (1.29e-4)**
SMOP3	1000	1.4290e+0 (1.40e-1) -	7.6321e-2 (8.35e-4) -	1.2819e+0 (1.20e-1) -	7.0081e-1 (4.48e-1) -	**3.9679e-3 (6.99e-5)**
SMOP4	1000	8.5606e-1 (8.21e-2) -	**3.9472e-3 (9.54e-7)** +	7.8554e-1 (1.44e-2) -	4.3849e-3 (2.12e-4) -	4.1348e-3 (7.80e-5)
SMOP5	1000	4.2849e-1 (1.03e-2) -	**4.3696e-3 (1.37e-4)** +	4.2782e-1 (3.76e-3) -	3.0317e-2 (8.38e-3) -	4.6126e-3 (1.32e-4)
SMOP6	1000	2.0522e-1 (1.77e-2) -	3.9742e-2 (5.53e-4) -	1.6821e-1 (4.95e-3) -	5.1000e-2 (4.53e-3) -	**4.6740e-3 (1.79e-4)**
SMOP7	1000	6.3636e-1 (8.29e-2) -	2.2425e-1 (1.27e-3) -	5.6495e-1 (4.84e-2) -	1.9515e-1 (7.89e-3) -	**4.6113e-3 (3.80e-4)**
SMOP8	1000	2.5260e+0 (3.87e-1) -	5.0612e-1 (4.92e-3) -	2.4972e+0 (6.64e-2) -	4.7219e-1 (2.85e-2) -	**1.4521e-1 (8.28e-3)**
+/-/=		0/8/0	2/6/0	0/8/0	0/8/0	

总体时间复杂度可总结为（参见方程（15））：

$$O(D^2 + T(N^2 + ND))(15)$$

当$D \gg N$时，复杂度由ND主导，而对于大量人口，N^2成为主要瓶颈。与 AGSEA 相比，SMAF 引入了 RealInit1 的额外初始化成本，但不改变渐近复杂度。

在实际运行时间方面，SMAF 在七个比较算法中表现出适中的计算成本。它通常比 AGSEA 慢，但差距仍在可接受范围内。MOEA/PSL 在许多情况下表现出更高的运行时开销，尽管在某些情况下可能优于 SMAF。跨 500、1000 和 2000 个决策变量的问题的运行时测量（见图 15）表明，SMAF 的扩展率与理论复杂度保持一致，随着问题维度的增加稳步增加，同时仍可与 AGSEA 比较。这表明强化学习模块引入了额外的开销，同时从根本上不影响可扩展性。

尽管取得了这些令人鼓舞的结果，SMAF 的一个显著局限是强化学习模块带来的额外计算成本。这些发现凸显了计算效率与解决方案质量之间的权衡：强化学习模块增加了运行时间，但有助于优化性能的提升。未来的工作可能会聚焦于轻量级学习策略或并行实施，以进一步减少这些开销。

5. 消融实验

5.1. 消融实验设计与适应度策略与作用空间分析

为评估不同适应度评估策略和动作空间设计对 AGSEA 算法性能的影响，开发了以下消融实验变体：

- AGSEA：原始算法，其中动作空间由三个动作组成。其中，动作 1 选择基于决策变量 OnthetraditionalPriorinformation $F1$，而 Actions2 和 3 保持不变。采取贪婪的行动选择策略。
- AGSEA-F2：基于 AGSEA，该版本用可变区间划分和固定值评估方案构建的先前信息$F1$替换了原先信息 b66a125d-52ec-4fe4-cd0c18d。动作空间保持不变。
- AGSEA-Fusion：基于 AGSEA，该版本引入了 F2，并用加权组合取代了原有的随机反馈适应度动作：$F1$和$F2$.。Theactionspaceremainschanged，其他动作保持不变。
- AGSEA-Softmax：基于原始 AGSEA 验证用基于 Softmax 的概率行动选择替代贪婪策略的效果。
- AGSEA-Final-NoSoftmax：基于 AGSEA-Fusion，该版本新增 sanewaction 源自 $F2$，扩展了行动空间以支持多种适应度评估策略。然而，行动选择仍遵循贪婪策略，未采用软极限机制。
- AGSEA-Final：该最终版本基于 AGSEA-FinalNoSoftmax，引入 Softmax 策略取代贪婪机制，允许基于行动分数进行概率性行动选择。它整合了新先前信息、行动空间扩展和选择策略的改进，代表了这些改进的整体整合。

AGSEA-F2 评估新的先验信息（F2）对变量选择表现的影响。AGSEA-Fusion 结合了 F1 和 F2 的加权组合，以评估反馈信号引导的增强效果。AGSEA-Softmax 引入 Softmax 策略，以研究其在动作选择过程中增加多样性和探索性的影响。AGSEA-Final-No-Softmax 扩展了行动空间，同时保留贪婪选择策略，以检验多种适应度评估策略的有效性。最后，AGSEA-Final 结合了适应度函数优化、作用空间展开和概率性动作选择，全面评估所提方法的整体性能。

如表 6 和表 10 所示，实验结果涵盖了两个主流绩效指标：免疫指数（IGD）和高密度（HV）。就适应度而言

表 8 SMAF 及其比较算法在 SMOP1-SMOP8 三目标基准问题上获得的 IGD 结果的平均和标准差，每行中最佳结果被突出显示。

Problem	D	MOEA/D-DQN	MOEA/D-DQN_Sparse	DRLOS-EMCMO	DRLOS-EMCMO_Sparse	SMAF
SMOP1	1000	5.8988e-1 (4.77e-2) -	8.0482e-2 (1.38e-3) -	6.0925e-1 (1.67e-2) -	1.3087e-1 (7.94e-3) -	**4.2502e-2 (4.26e-4)**
SMOP2	1000	1.5865e+0 (1.04e-1) -	1.4425e-1 (3.21e-3) -	1.7552e+0 (2.29e-2) -	1.9241e-1 (1.23e-2) -	**5.3650e-2 (1.81e-3)**
SMOP3	1000	1.3109e+0 (9.91e-2) -	2.4027e-1 (1.72e-1) -	1.5064e+0 (4.40e-2) -	1.0451e+0 (1.26e-1) -	**4.3775e-2 (7.98e-4)**
SMOP4	1000	6.0923e-1 (1.41e-2) -	3.6417e-2 (4.19e-2) -	6.4806e-1 (8.99e-3) -	4.5699e-2 (4.35e-3) -	**3.0576e-2 (6.13e-4)**
SMOP5	1000	2.7878e-1 (7.20e-3) -	6.8461e-2 (8.70e-2) -	3.1904e-1 (1.01e-2) -	1.0090e-1 (1.43e-2) -	**3.1921e-2 (8.41e-4)**
SMOP6	1000	1.5067e-1 (7.10e-3) -	5.1281e-2 (4.61e-2) -	1.8812e-1 (8.05e-3) -	1.1176e-1 (1.51e-2) -	**3.1497e-2 (5.89e-4)**
SMOP7	1000	8.1833e-1 (1.01e-1) -	2.3688e-1 (1.33e-3) -	7.8725e-1 (4.75e-2) -	2.7861e-1 (9.86e-3) -	**6.2912e-2 (9.03e-4)**
SMOP8	1000	2.8977e+0 (3.21e-1) -	5.1727e-1 (1.83e-3) -	3.7018e+0 (1.75e-2) -	5.7296e-1 (2.58e-2) -	**2.1573e-1 (1.14e-2)**
+/-/=		0/8/0	0/8/0	0/8/0	0/8/0	

表 9 SMAF 及其比较算法在 SMOP1-SMOP8 三目标基准问题中获得的 HV 结果均值和标准差，每行最佳结果被突出显示。

Problem	D	DRLOS-EMCMO	DRLOS-EMCMO_Sparse	MOEA/D-DQN	MOEA/D-DQN_Sparse	SMAF
SR	512	3.4218e-1 (1.36e-2) -	2.4454e-1 (2.25e-2) -	3.4806e-1 (1.35e-2) -	3.4973e-1 (1.08e-2) -	**3.7681e-1 (2.66e-3)**
	1024	3.3651e-1 (1.59e-2) -	2.8454e-1 (1.33e-2) -	3.4087e-1 (1.43e-2) -	3.3867e-1 (7.99e-3) -	**3.9387e-1 (1.13e-3)**
	2048	3.0020e-1 (2.04e-2) -	2.4473e-1 (1.69e-2) -	3.0678e-1 (1.07e-2) -	3.0950e-1 (8.62e-3) -	**3.7910e-1 (9.27e-4)**
+/-/=		0/3/0	0/3/0	0/3/0	0/3/0	

表 10 AGSEA、AGSEA-F2、AGSEA-Fusion、AGSEA-Softmax、AGSEA-Final-NoSoftmax 和 AGSEA-Final 在双目标 SMOP1－SMOP8 上获得的 HV 值，涵盖 500 个决策变量。每行中最佳结果都会被高亮显示。

Problem	D	AGSEA	AGSEA-F2	AGSEA-Fusion	AGSEA-Softmax	AGSEA-Final- NoSoftmax	AGSEA-Final
SMOP1	500	5.8128e-1 (1.55e-4) =	5.7348e-1 (7.73e-3) -	5.8105e-1 (5.45e-4) -	5.8122e-1 (3.76e-4) =	5.8100e-1 (8.05e-4) -	**5.8134e-1 (1.60e-4)**
SMOP2	500	5.7960e-1 (2.16e-3) -	5.7935e-1 (2.30e-3) -	5.8009e-1 (9.10e-4) -	5.7976e-1 (1.51e-3) -	5.8055e-1 (6.93e-4) =	**5.8066e-1 (7.48e-4)**
SMOP3	500	5.8137e-1 (5.66e-4) -	5.7873e-1 (1.04e-2) =	5.8149e-1 (1.17e-4) -	5.8117e-1 (9.41e-4) =	5.8150e-1 (3.68e-4) =	**5.8158e-1 (2.36e-4)**
SMOP4	500	8.1868e-1 (4.45e-5) =	8.1868e-1 (4.88e-5) =	8.1869e-1 (5.88e-5) =	8.1867e-1 (6.10e-5) =	**8.1870e-1 (5.14e-5)** +	8.1868e-1 (5.02e-5)
SMOP5	500	8.1557e-1 (4.84e-4) -	8.1595e-1 (4.66e-4) -	8.1596e-1 (5.74e-4) -	8.1575e-1 (4.69e-4) -	8.1643e-1 (3.75e-4) -	**8.1668e-1 (4.34e-4)**
SMOP6	500	8.1432e-1 (6.26e-4) -	8.1482e-1 (4.09e-4) -	8.1497e-1 (5.10e-4) -	8.1467e-1 (6.71e-4) -	8.1518e-1 (4.23e-4) -	**8.1546e-1 (3.37e-4)**
SMOP7	500	3.0497e-1 (1.16e-2) -	**3.4228e-1 (8.22e-3)** +	3.2409e-1 (2.66e-2) =	3.0475e-1 (1.38e-2) -	3.2466e-1 (3.80e-2) =	3.2047e-1 (3.94e-2)
SMOP8	500	1.0945e-1 (1.07e-2) -	**1.5832e-1 (1.11e-2)** =	1.3658e-1 (3.05e-2) -	1.1341e-1 (1.11e-2) -	1.4613e-1 (2.95e-2) =	1.5170e-1 (2.56e-2)
+/-/=		0/6/2	1/4/3	0/6/2	0/5/3	1/3/4	

表 11 AGSEA 和 AGSEA-SG 在双目标 SMOP1－SMOP8 上获得的 IGD 值，包含 500 个决策变量。每行的最佳成绩都会被高亮显示。”+’，’－’，且 ’ ”≈”表明，另一家 MOEA 的结果优于、更差或与 AGSEA-SG 的得出相当。

Problem	D	AGSEA	AGSEA-SG
SMOP1	500	4.0410e-3 (7.05e-5) -	**3.9963e-3 (8.72e-5)**
SMOP2	500	4.9007e-3 (1.34e-3) -	**4.3602e-3 (2.52e-4)**
SMOP3	500	**3.9762e-3** (2.46e-4) =	4.0895e-3 (3.29e-4)
SMOP4	500	4.1312e-3 (6.86e-5) =	**4.1169e-3** (7.88e-5)
SMOP5	500	5.4374e-3 (3.02e-4) -	**5.2840e-3** (3.93e-4)
SMOP6	500	6.2892e-3 (4.55e-4) -	**5.2198e-3** (2.20e-4)
SMOP7	500	3.3834e-2 (8.22e-3) -	**5.2131e-3** (8.29e-4)
SMOP8	500	2.0552e-1 (1.45e-2) -	**1.4146e-1** (1.02e-2)
+/-/=		0/6/2	

表 12 AGSEA 和 AGSEA-SG 在双目标 SMOP1－SMOP8 上获得的 HV 值，包含 500 个决策变量。每行中最佳结果都会被高亮显示。

Problem	D	AGSEA	AGSEA-SG
SMOP1	500	5.8128e-1 (1.55e-4) -	**5.8137e-1 (1.73e-4)**
SMOP2	500	5.7960e-1 (2.16e-3) -	**5.8051e-1 (4.82e-4)**
SMOP3	500	**5.8137e-1** (5.66e-4) =	5.8108e-1 (8.06e-4)
SMOP4	500	8.1868e-1 (4.45e-5) =	**8.1870e-1** (5.19e-5)
SMOP5	500	8.1557e-1 (4.84e-4) =	**8.1579e-1** (6.40e-4)
SMOP6	500	8.1432e-1 (6.26e-4) -	**8.1595e-1** (3.72e-4)
SMOP7	500	3.0497e-1 (1.16e-2) -	**3.4578e-1** (1.49e-3)
SMOP8	500	1.0945e-1 (1.07e-2) -	**1.6406e-1** (9.58e-3)
+/-/=		0/5/3	

函数优化，AGSEA-F2 采用基于变量划分和相关分析的新构造先验信息（F2），以取代原版 Fitness1。尽管该方法在三个测试问题上与最终版本性能相当，但在 SMOP1 和 SMOP2 上表现不如基线 AGSEA，表明单一评估机制难以平衡全局探索和局部利用。关于高超，AGSEA-F2 未达到 fi

表 13 不同 AGSEA 变体在基准稀疏多目标问题上的 IGD 性能比较。每行中最佳结果都会被高亮显示。

Problem	D	AGSEA	AGSEA-MA	AGSEA-SG	AGSEA-HF
SMOP1	500	4.0410e-3 (7.05e-5) -	4.0140e-3 (7.22e-5) -	3.9963e-3 (8.72e-5) =	**3.9619e-3 (8.36e-5)**
SMOP2	500	4.9007e-3 (1.34e-3) -	4.3092e-3 (3.81e-4) =	4.3602e-3 (2.52e-4) -	**4.1920e-3 (1.28e-4)**
SMOP3	500	3.9762e-3 (2.46e-4) =	**3.8958e-3 (9.35e-5)** +	4.0895e-3 (3.29e-4) =	3.9621e-3 (1.38e-4)
SMOP4	500	4.1312e-3 (6.86e-5) =	4.1465e-3 (6.91e-5) =	**4.1169e-3 (7.88e-5)** =	4.1370e-3 (4.54e-5)
SMOP5	500	5.4374e-3 (3.02e-4) -	4.8317e-3 (2.22e-4) =	5.2840e-3 (3.93e-4) -	**4.7501e-3 (2.05e-4)**
SMOP6	500	6.2892e-3 (4.55e-4) -	5.4836e-3 (2.26e-4) -	5.2198e-3 (2.20e-4) -	**4.7966e-3 (1.99e-4)**
SMOP7	500	3.3834e-2 (8.22e-3) -	2.2368e-2 (2.76e-2) -	5.2131e-3 (8.29e-4) -	**4.4017e-3 (9.68e-5)**
SMOP8	500	2.0552e-1 (1.45e-2) -	1.5613e-1 (3.22e-2) =	**1.4146e-1 (1.02e-2)** =	1.4214e-1 (9.32e-3)
+/-/=		0/6/2	1/3/4	0/4/4	

表 14 不同 AGSEA 变体在基准稀疏多目标问题上的高压性能比较。每行中最佳结果都会被高亮显示。

Problem	D	AGSEA	AGSEA-MA	AGSEA-SG	AGSEA-HF
SMOP1	500	5.8128e-1 (1.55e-4) -	5.8134e-1 (1.60e-4) -	5.8137e-1 (1.73e-4) =	**5.8145e-1 (1.71e-4)**
SMOP2	500	5.7960e-1 (2.16e-3) -	5.8066e-1 (7.48e-4) =	5.8051e-1 (4.82e-4) -	**5.8090e-1 (2.70e-4)**
SMOP3	500	5.8137e-1 (5.66e-4) =	**5.8158e-1 (2.36e-4)** +	5.8108e-1 (8.06e-4) =	5.8141e-1 (3.39e-4)
SMOP4	500	8.1868e-1 (4.45e-5) =	8.1867e-1 (4.88e-5) =	**8.1870e-1 (5.19e-5)** =	8.1868e-1 (3.50e-5)
SMOP5	500	8.1557e-1 (4.84e-4) -	8.1668e-1 (4.34e-4) =	8.1579e-1 (6.40e-4) -	**8.1680e-1 (3.56e-4)**
SMOP6	500	8.1432e-1 (6.26e-4) -	8.1546e-1 (3.37e-4) -	8.1595e-1 (3.72e-4) -	**8.1668e-1 (3.33e-4)**
SMOP7	500	3.0497e-1 (1.16e-2) -	3.2047e-1 (3.94e-2) -	3.4578e-1 (1.49e-3) -	**3.4656e-1 (2.11e-4)**
SMOP8	500	1.0945e-1 (1.07e-2) -	1.5170e-1 (2.56e-2) =	**1.6406e-1 (9.58e-3)** =	1.6351e-1 (8.91e-3)
+/-/=		0/6/2	1/3/4	0/4/4	

NAL 版本在四个以上问题上，进一步证实了其在传递表达性反馈信号方面的能力有限。

AGSEA-Fusion 通过加权并结合 Fitness1 和 Fitness2，增强反馈信号表达力。在大多数问题上，从 SMOP2 到 SMOP8，它比原始 AGSEA 实现了更好的 IGD 结果，尤其在 SMOP7 和 SMOP8 上有显著改进。这表明融合策略对多样性的保存和趋同都具有积极贡献。然而，就高压而言，AGSEAFusion 在大多数情况下仍低于最终版本，表明在近似帕累托前边界方面还有改进空间。

在动作选择方面，AGSEA-Softmax 引入了概率性 Softmax 机制，取代贪婪选择，进行指数映射和动作分数归一化，从而实现基于概率的抽样。尽管理论上促进了政策多样性，但 IGD 和 HV 的结果显示，它未能在六个测试问题上实现改进，表明单独使用 Softmax 策略时不够充分，必须与其他改进整合才能发挥其全部潜力。

AGSEA-Final-No-Softmax 通过整合多种基于体能的动作反馈方案，扩展了动作空间，同时保留了最初的贪婪机制。该变体在 SMOP2、SMOP5 和 SMOP6 的 IGD 和 HV 指标上均优于 AGSEA，验证了动作空间扩展的积极效果。然而，其性能仍不及最终版本，尤其是在 SMOP1 和 SMOP2 上，表明 Softmax 机制在复杂场景下的动作采样指导中起着关键的补偿作用。这些发现支持了在最终设计中将 Softmax 与其他策略结合的理论和实证必要性。

最终版本 AGSEA-Final 整合了新的先验信息、反馈融合、动作空间扩展和基于 Softmax 的采样。它在所有八个测试题中都取得了最佳或统计上等效的表现。在 IGD 方面，AGSEA-Final 在六个问题上优于原始 AGSEA（例如 SMOP7 提升 33.9%，SMOP8 提升 24%），大多数情况下标准差减少 30% 至 50%。在高压方面，AGSEA-Final 在多个问题上也表现出优越性，尤其是在 SMOP5、SMOP6 和 SMOP8 上稳定地优于 AGSEA。这些结果共同凸显了多样性提升的双重优势以及收敛质量，验证所提多策略协作机制的有效性和普遍适用性。

此外，图 16 进一步可视化了每个算法在基准问题上的平均 IGD 表现。结果明确显示，AGSEA-Final 在多个问题上优于所有其他变体，SMOP7 和 SMOP8 的改进尤为显著。这证明了所提多策略协作机制在增强收敛性和鲁棒性方面的有效性。图 17 提供了六个 SMOP 问题中基于 IGD 的排名热图。每个格子显示排名，深色代表性能较佳。AGSEA-Final 在 8 个测试题中有 5 个表现最好。尽管其在 SMOP4 问题上的表现相对较弱，但该问题所有算法的整体 IGD 值非常接近，差异可忽略不计。因此，SMOP4 的表现并未显著削弱 AGSEA-Final 的整体竞争力。

进一步分析显示，AGSEA-Final 不仅在大多数问题上实现了更优的平均 IGD 值，还表现出更小的标准差，表明其稳定性和鲁棒性更强。具体来说，它在涵盖多样分布特性和问题复杂度的 SMOP1、SMOP3、SMOP5、SMOP6 和 SMOP8 上取得了最佳结果。这凸显了所提算法良好的泛化能力。

5.2. 稀疏引导作用空间设计的消融研究

为评估新引入的稀疏导导调整模块带来的性能提升，我们进行了消融实验。在这些实验中，我们将包含稀疏制导机制的算法与排除该模块的基线版本进行了比较。

具体来说，稀疏引导模块动态调整掩体中变量的激活比，以保持个体稀疏度在非显性解中观察到的合理范围内。它还整合了适应度信息来指导变量选择，从而提升搜索效率和解决方案质量。基线版本是原始算法，没有稀疏引导调整模块，其他作符和参数保持不变。

IGD 表现比较 SMOP 问题上 SMAF 策略的($D = 500$) 加粗值表示最佳结果。表 15

Problem	D	SMAF_Early_Fast	SMAF_Late_Fast	SMAF_Mid_Fast	SMAF_Mid_Slow	SMAF
SMOP1	500	3.9740e-3 (7.47e-5) =	**3.9619e-3 (7.32e-5)** =	3.9848e-3 (8.08e-5) =	3.9819e-3 (7.19e-5) =	3.9875e-3 (1.22e-4)
SMOP2	500	4.2316e-3 (2.06e-4) =	**4.1576e-3 (1.31e-4)** =	4.1849e-3 (1.54e-4) =	4.2046e-3 (1.42e-4) =	4.1842e-3 (1.55e-4)
SMOP3	500	3.9563e-3 (1.81e-4) =	4.0318e-3 (3.47e-4) =	**3.9041e-3 (5.41e-5)** =	3.9307e-3 (1.51e-4) =	3.9079e-3 (4.18e-5)
SMOP4	500	4.1422e-3 (5.93e-5) =	4.1401e-3 (7.44e-5) =	**4.1187e-3 (6.52e-5)** =	4.1228e-3 (7.12e-5) =	4.1345e-3 (6.45e-5)
SMOP5	500	4.9046e-3 (2.09e-4) =	**4.7670e-3 (1.93e-4)** =	4.7878e-3 (2.18e-4) =	4.8013e-3 (1.89e-4) =	4.8056e-3 (2.50e-4)
SMOP6	500	4.7918e-3 (2.17e-4) +	4.8496e-3 (2.09e-4) =	4.8415e-3 (2.45e-4) =	**4.7772e-3 (1.42e-4)** +	4.9256e-3 (2.40e-4)
SMOP7	500	4.8339e-3 (1.26e-3) =	**4.4249e-3 (1.29e-4)** =	4.5982e-3 (4.96e-4) =	4.5719e-3 (5.14e-4) =	4.6119e-3 (8.66e-4)
SMOP8	500	1.3998e-1 (9.98e-3) =	1.4197e-1 (9.32e-3) =	1.3932e-1 (7.68e-3) =	1.4193e-1 (8.54e-3) =	**1.3861e-1 (7.76e-3)**
+/-/=		1/0/7	0/0/8	1/0/7	0/0/8	

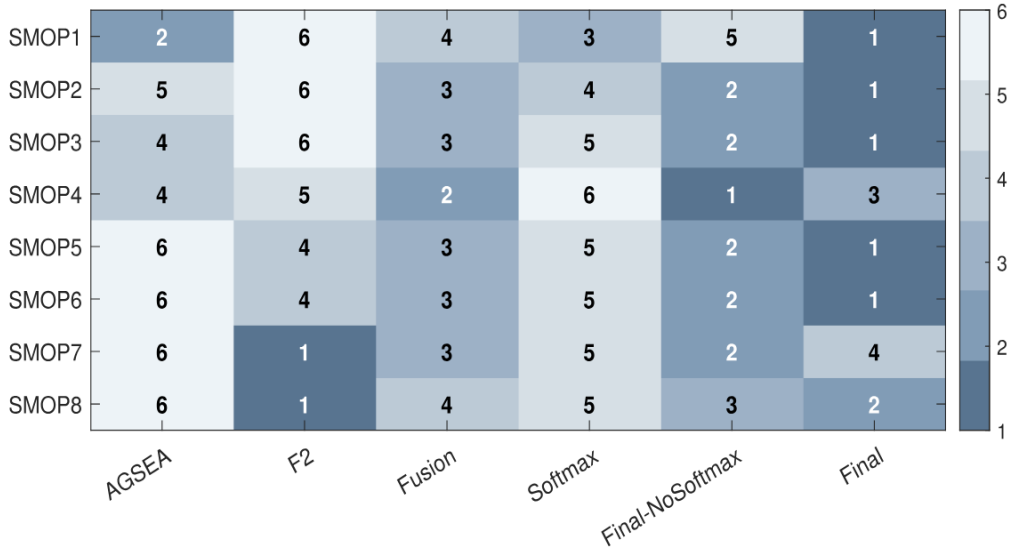


图 17。基于 IGD 的 AGSEA 及其变体在双目标 SMOP1 - SMOP8 问题（500 个决策变量）排名热图。对于每个问题（行），排名越低表示表现越好，颜色越深代表排名越好。

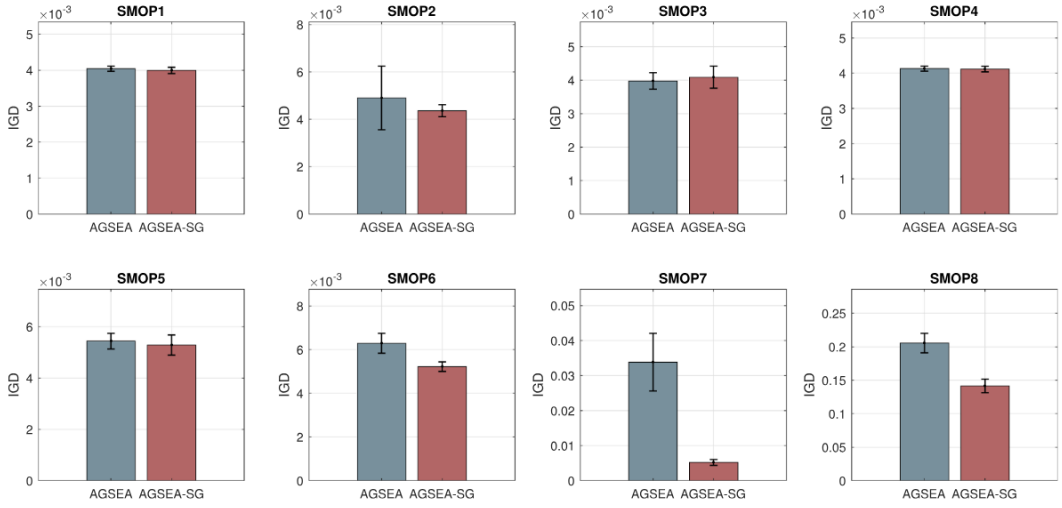


图 18。AGSEA 和 AGSEA-SG 在双目标 SMOP1-SMOP8 上的 IGD 表现，包含 500 个决策变量。

通过比较这两个版本，我们评估了稀疏引导模块在控制掩膜稀疏性和提升进化搜索性能方面的实际贡献。

表 11 展示了 AGSEA 和 AGSEA-SG 在 SMOP 基准问题上的 IGD 表现。图 18 进一步可视化了每个算法在基准问题上的平均 IGD 表现。交流

根据表 11 的分析，AGSEA-SG 在大多数测试问题上优于或匹敌 AGSEA。具体来说，在八个测试问题中，AGSEA-SG 在七个问题上实现了更好的免疫缺陷值，其中六个问题的表现优于 AGSEA。只有在 SMOP3 上，AGSEA 的表现略优于 AGSEA-SG。在统计结果方面，AGSEA-SG 显示出六项优势，零缺点和两种

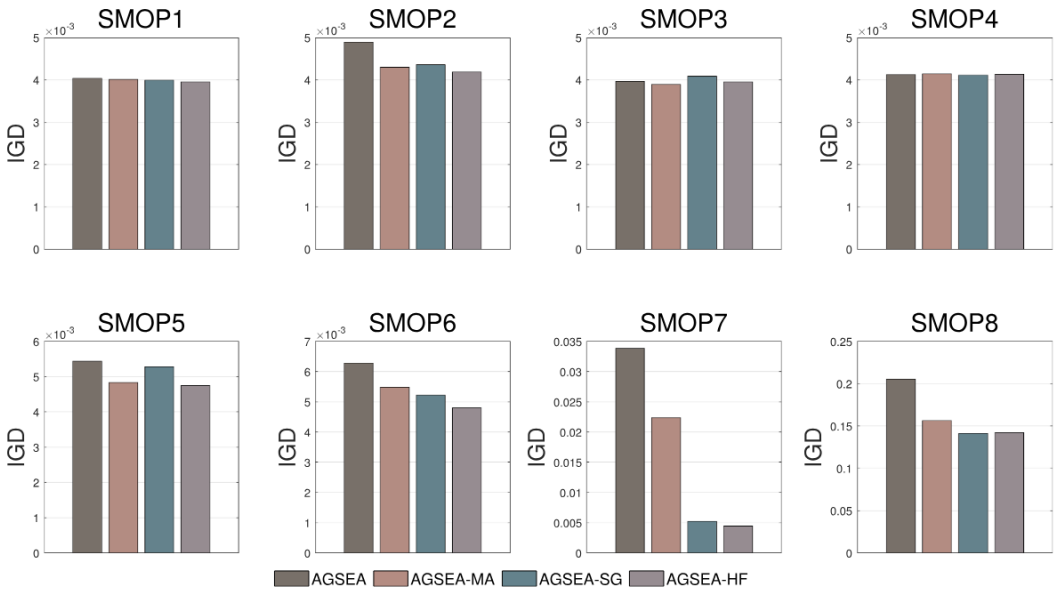


图 19。AGSEA 及其变体在双目标 SMOP1 - SMOP8 上的 IGD 性能，具有 500 个决策变量。

与 AGSEA 的平局相比。这些结果表明，引入稀疏引导机制显著增强了算法保持解集收敛性和多样性的能力。

此外，表 12 还以 HV 指标进行了性能比较。结果显示 AGSEA-SG 也表现出更优的 HV 值。在八个问题中，AGSEA-SG 在五个问题上优于 AGSEA，其余三个问题并列，且无表现较差。这些发现进一步验证了 AGSEA-SG 在提升整体溶液质量方面的有效性。值得注意的是，在 SMOP7 和 SMOP8 上，AGSEA-SG 分别提升了约 13.4% 和 49.9% 的 HV 值，显示其在改善目标空间种群覆盖率的同时，保持收敛的能力增强。

总之，AGSEA-SG 通过将稀疏引导调整模块集成到 AGSEA 中，展示了 IGD 和 HV 指标的性能提升。这一改进有助于提高高维多目标优化问题中解集的收敛速度和分布质量，也可能提升算法对复杂帕累托前沿结构的适应性。

5.3. 消融实验与融合机制的协同效应分析

为了彻底探讨所提模块的各个贡献及其综合效应，我们对代表性基准稀疏多目标优化问题进行了一系列消融实验。具体来说，我们重点评估稀疏引导机制和多作用选择结合适应度驱动调整的优化能力，以及它们的整合是否带来任何协同效应。这些实验旨在验证每个组件在收敛性能和解多样性方面的有效性，并进一步探索模块间潜在的互补性。

涉及的算法变体定义如下：

- AGSEA-MA：在第 5.1 节中也称为 AGSEA-Final，该版本包含多行动选择策略和适应度驱动的调整机制，增强了行动执行的适应性。
- AGSEA-SG：该变体集成了稀疏度引导的突变机制，能够根据稀疏度反馈自适应地调整变量选择策略（见第 5.2 节）。
- AGSEA-HF：这是一种混合融合版本，结合了稀疏引导机制和多重作用体能增强策略。目标是利用它们互补的优势，评估其协同效应。

表 13 和表 14 中呈现的结果表明，最终集成版本同时包含稀疏度引导和多动作选择机制，在 8 个测试题中有 5 个实现了最佳或接近最佳的 IGD 表现。这表明这两个模块在搜索策略中具有强烈的互补性和协同增强。此外，图 19 进一步可视化了每个算法在基准问题上的平均 IGD 表现。与此同时，在 HV 指标方面，集成版表现良好，保持了解决方案集的多样性和大多数问题的覆盖范围。尽管该整合策略在某些问题上表现略逊于某些模块，但总体而言，该整合提升了算法的适应性和鲁棒性，实现收敛与多样性之间的良好平衡，从而展现出更稳定和更优越的优化性能。

5.4. 参数敏感性分析

为了系统性地研究训练开始时间和网络更新频率对 SMAF 性能的影响，我们定义了两个关键参数：训练启动比率（TSR）和更新间隔（UI）。基于这些参数的不同组合设计了四个变体：

- SMAF_Early_Fast $TSR = 0.1$， $UI = 10$通过频繁网络更新早早开始训练，实现快速收敛但可能不稳定。
- SMAF_Late_Fast $TSR = 0.5$，$UI = 10$ 因频繁更新而延迟训练，导致收敛速度变慢且计算成本更高。
- SMAF_Mid_Fast $TSR = 0.25$ $UI = 5$ 中期开始频繁更新，提供适度收敛。
- SMAF_Mid_Slow $TSR = 0.25$ $UI = 20$：中期阶段开始，更新稀疏，导致趋同速度较慢但更稳定。

从表 15 来看，大多数 SMAF 变体在大多数测试实例中达到与原始 SMAF 相当的 IGD 值。具体来说，对于 SMOP1 - SMOP5 和 SMOP7 - SMOP8，这些变体的 IGD 值

与基线相似，标准差表示表现分布重叠，表明策略间无显著差异。唯一显著的例外是 SMOP6，SMAF_Mid_Slow 和 SMAF_Early_Fast 的 IGD 值较低，标准差相对较小，显示出明显的改进。总体而言，虽然部分变体偶尔在特定情况下略有优势，但整体性能差异有限，大多数变体的性能与原始 SMAF 相似。

这些发现表明，在测试设置下，SMAF 算法对训练启动比率（TSR）和网络更新间隔（UI）的变化敏感度较低。尽管训练启动的早期或延迟以及频繁或稀疏的网络更新可能影响单个问题的收敛速度，但它们对最终 IGD 值的影响有限。这表明算法的整体收敛行为和解决方案质量在这两个参数下具有稳健性，微调 TSR 和 UI 不太可能为大多数 SMOP 实例带来显著性能提升。

6. 结论

本文探讨了 AGSEA 算法在泛化能力和稀疏度控制方面对大规模稀疏多目标优化问题的局限性。我们提出了 SMAF，一种将深度强化学习与结构引导机制整合的新型进化优化框架。SMAF 采用结构感知抽样捕捉决策变量之间的依赖关系，采用基于 Softmax 的动作选择策略提升搜索多样性和稳定性，并采用自适应反馈机制调节稀疏性。通过动态选择具有代表性的引导向量，它高效生成稀疏且分布良好的解集。

对基准问题和实际应用的广泛实验 —— 包括稀疏信号重建、临界节点检测和高维特征选择 —— 表明 SMAF 在提供实用优势的同时，实现了竞争或更优的性能。在稀疏信号重建中，它平衡稀疏性和重建精度，降低测量成本。对于关键节点检测，它识别计算负担最小的关键节点，支持网络设计和鲁棒性分析。在特征选择中，SMAF 高效地选择信息性特征，以提高预测性能并避免过拟合。这些结果凸显了 SMAF 在现实稀疏优化任务中的适用性。

总体而言，SMAF 既提供了一个有效的算法解决方案，也是一个广泛适用的框架，桥接进化计算与强化学习。未来的研究可以探索领域特定的启发式方法，以定制引导向量，或利用多智能体强化学习协同选择多样化的变异算子，进一步提升收敛速度和解质量。此类发展有望扩大 SMAF 在需要稀疏高质量解决方案的应用中的实际影响力。

CRediT 作者贡献声明

ShuZhao Pang：方法论、调查、软件、写作 —— 原始草稿、验证、可视化、数据整理、形式分析。张清柯：构思、方法论、调查、写作 —— 原稿、写作 —— 审阅与编辑、软件、监督、项目管理、资金获取。陈志辉：写作 —— 书评与编辑，资源。李俊静：写作 —— 书评与编辑，资源。张华翔：写作 —— 审稿与编辑，资源，资金获取。

数据可用性

数据将根据要求提供。

利益竞争声明

作者声明他们没有已知的竞争性财务利益或个人关系，这些关系可能影响本文报道的工作。

致谢

该工作得到了中国国家自然科学基金（编号 62006144）和山东泰山学者项目（编号 ts20190924）的支持。

参考文献

阿格拉瓦尔，R.，和斯里坎特，R.（1994）。快速算法，挖掘关联规则。在第 20 届 VLDB 会议（第 487–499 页）。

博斯曼，P. A. N.，和蒂伦斯，D.（2003）。邻近性与多样性之间的平衡多目标进化算法。《IEEE 进化计算汇刊》，7（2），174–188。

朱志明、庄志、潘志志、穆罕默德、胡志明。（2024）。增强型稀疏 EA 用于大规模多目标特征选择问题。《复杂与智能系统》，10（1），485–507。

科彭斯，R.，雷伊宁，R.，张，Y.，布利克，L.，和斯廷豪森，B.（2022）。学习 ADAP-用于解决多目标优化问题的演化计算。arXiv：2211.09719。

德拉克，J.，加西亚，S.，莫利纳，D.，和埃雷拉，F.（2011）。关于使用方法的实用教程非参数统计测试的一种比较进化方法论

群体智能算法。《群体与进化计算》，1（1），3–18。丁、曹、L.、陈、孙、X.、张、Z.（2023）。基于混合层次聚类的大规模多模态多目标进化优化。知识型系统，266,110398。

丁、Z.、陈、孙、D.、张、X.（2022）。一种多阶段知识引导的进化算法，用于大规模稀疏多目标优化问题。《群体与进化计算》，73 卷，101119。

丁梓、陈宇、孙大、张晓、刘宇（2024）。高效稀疏的大规模多分子 —— tiobjectiveoptimizationbasedon 跨尺度知识融合。IEEE 系统、人类与控制论研究：系统，54（11），6989–7001。

Fischer， A. 和 Igel， C.（2012）。限制玻尔兹曼机械入门。载于《伊比利亚美洲模式识别大会》（第 14–36 页）。施普林格出版社。

耿浩、沈志、周、Z.、徐 K.（2023）。一种改进的大规模稀疏多目标进化算法，利用无监督神经网络。《应用智能》，53（9），10290–10309。

哈桑扎德，R.，莫贾维尔，P.，阿兹达斯特，T.，卡利拉里亚，S.，和奇察兹，A.（2023）。利用响应面方法作为机器学习技术和多目标优化方法，开发聚乙烯废弃物的气化工艺。《国际氢能杂志》，48（15），5873–5886。

何、C.、程、R.、张 C.、田、Y.、陈 Q.、姚、X.（2020）。电压互感器比误差估计的进化大规模多目标优化。《IEEE 进化计算汇刊》，24（5），868–881。

何，R.，卞，R.，华，J.，赵，L.，徐，F.，和龙，J.（2025）。多目标优化通过 NSGA-II 算法与复合算子进行调度，con-sidering 油的移动路径规划。ExpertSystemswithApplications，280,127426。

胡、泽、聂晓、孙浩、魏、L.、张志、干昌（2025）。稀疏的大规模多重 —— 目标：基于影响因子协助的优化算法。《人工智能的工程应用》，151 卷，110615。

卡里米，F.，道拉特沙希，M. B.，和哈希米，A.（2023）。半 ACO：半监督的 FEA-tureselectionbasedonantcolonyoptimization。ExpertSystemswithApplications，214,119130。

Khishe， M.， Orouji， N.， 和 Mosavi， M. R.（2023）。多目标黑猩猩优化器：一种用于多目标问题的创新算法。《专家系统与应用》，第 211 卷，118734。

克罗普，T.，内蒂达谢米，A. P.，和德布，K.（2023）。改进的进化算子稀疏大规模多目标优化问题。IEEE 进化计算的 ransactionson，28（2），460–473。

拉卢，M.，塔赫拉维，M. A.，和 凯杜奇，H.（2018）。网络中的关键节点检测问题：一项综述。《计算机科学评论》，29,89–117。

李鹏、张耀、杨鹏、姚晓、周、A.（2023）。一个两总体算法基于适应度意识操作员和适应性环境选择的大规模多目标优化。《IEEE 进化计算汇刊》，29（3），631–645。

Li， F.， Liu， J.， 和 Yu， Y.（2025）。基于深度强化学习的多目标优化算法由力 – 燃气 – 热能集成能源系统的 MISTATION。专家系统与应用 —— 262,125559。

Li， Y.， Feng， X.， 和 Yu， H.（2024）。一个动态的知识引导共进化算法对于大规模稀疏多目标优化问题。IEEETransactiononSystems， Man， and Cybernetics：

梁志、龚、李浩、岳志、曲伯（2018）。CEC 稀疏算法进化算法专场的问题定义与评估标准，CEC 稀疏优化进化算法专场的标准。郑州大学计算智能实验室技术报告，中国郑州，报告 #201809。

刘志、和刘、P.（2024）。一个双元越分解法与多重大规模多目标优化策略 可能的 lems。《信息科学》，678,120950。

刘 J.、萨克尔、埃尔赛义德、埃萨姆、D. 埃萨姆和西斯万托 N.（2024）。大规模进化优化：综述与比较研究。《群体与进化计算》，85，第 101466。

马浩、张耀、孙修、刘 T、山耀（2023）。NSGA-II 的综合综述，旨在多目标优化和应用。《人工智能评论》，56（12），15217 - 15270。

麦凯，M. D.，贝克曼，R. J.，和康诺弗，W. J.（2000）。比较计算机代码输出分析中选择输入变量值的三种方法。《技术计量学：物理、化学与工程科学统计学杂志》，42（1），55 - -。

明，F.，龚，W.，王，L.，和金，Y.（2024）。受限多目标优化，辅以深度强化学习辅助操作员选择。IEEE/CAA 《中华自动机杂志》，11（4），919 - 931。

Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., 和 Riedmiller, M.（2013）。玩 Atari 时，采用深度强化学习。arXiv：1312.5602。

彭，Y.，和石渊，H.（2020）。一种基于分解的大规模多模态多目标优化算法。2020 年 IEEE 进化计算大会（CEC）（第 1 - 8 页）IEEE。

拉朱，M. R.，和莫斯库，S. K.（2023）。雾化物联网应用的延迟与能量感知任务调度机制：一种强化学习方法。《计算机网络》，第 224 卷，109603。

任 T.、邱 F.、胡 H.（2023）。基于多重稀疏检测的进化算法对于大规模稀疏多目标优化问题。《复杂与智能系统》，9（4），4369 - 4388。

尚、谭、M.、胡、R.、黄毅、钱 B.、冯、L.（2025）。一种多阶段竞争性群体优化算法，用于解决大规模多目标优化问题。《专家系统与应用》，第 260 页，125411。

邵 S.、田 Y.、张 X.（2024）。深度强化学习辅助的引导向量选择，实现大规模稀疏多目标优化。《群体与进化计算》，88,101606。

Sharma, S. 和 Kumar, V.（2022）。关于多目标优化技术的全面综述：过去、现在与未来。《工程计算方法档案》，29（7），5605 - 5633。

Siraskar, R., Kumar, S., Patil, S., Bongale, A. 和 Kotecha, K.（2023）。强化学习用于预测维护：系统技术综述。人工智能评论，56（11），12885 - 12947. 孙，Y.，& 江，D.（2024）。一种改进型问题转换算法，用于大规模多目标优化。《群体与进化计算》，89,101622。

田，M.，陈，M.，杜，W.，唐，Y.，和金，Y.（2024a）。一种针对大规模重叠问题的增强微分分组方法。《IEEE 进化计算汇刊》。

田宇、程宇、张晓、金宇（2017）。PlatEMO：一个用于进化多目标优化的 MATLAB 平台【教育论坛】。IEEE 计算智能杂志，12（4），73 - 87。AGSEA 实现可于：https://github.com/BIMK/PlatEMO/tree/master/PlatEMO/Algorithms/ 多目标 %20 优化 / AGSEA。

Tian, Y., Feng, Y., Zhang, X., 和 Sun, C.（2022a）。一种基于快速聚类的进化算法，超大规模稀疏多目标优化算法。IEEE/CAA 期刊《AutomaticaSinica》，10（4），1048-1063。

Tian, Y., Li, X., 马, H., 张 X., 谭, K. C. 和 Jin, Y.（2022b）。基于深度强化学习的自适应操作员选择，用于进化多目标作 - 刺激。《IEEE 计算智能新兴议题汇刊》，7（4），1051 - 1064。

田宇、刘 R.、张晓、马、H.、谭 K. C.、金、Y.（2020a）。多族群用于解决大规模多模态多目标优化问题的进化算法。IEEE 进化计算的 ransactions，25（3），405 - 418。

Tian, Y., Lu, C., 张 X., Tan, K. C. 和 Jin, Y.（2020b）。解决大规模多元题 —— 通过无监督神经网络的简易优化问题与稀疏最优解。《IEEE 控制论汇刊》，51（6），3115 - 3128。

Tian, Y., Shao, S., 谢 G., & 张, X.（2024b）。一种基于多粒度聚类的进化算法，用于大规模稀疏多目标优化。《群体与进化计算》，84 卷，101453。

田宇、司永、张晓、程、何、C、谭、K. C. 和 金（2021）。进化大规模多目标优化：一项综述。ACM 计算调查（CSUR），54（8），1 - 34。

田宇、张晓、王昌、金宇（2019）。一种用于大规模稀疏多目标优化问题的进化算法。《IEEE 进化计算汇刊》，24（2），380 - 393。

陈浩荣、端永、梁永、斌荣（2023）。一个两阶段多目标进化强化学习框架，用于连续机器人控制。载于《遗传与进化计算会议论纲》（第 577 - 585 页）。

Verma, S., Pant, M., 和 Snasel, V.（2021）。NSGA-II 多重 —— 目标组合优化问题。IEEEAccess，9,57757 - 57791。

王（Q.）、张（Q.）、张（Q.）、孟（F.）、李（B.）（2023a）。基于目标层级的大规模进化算法，用于改善神经网络的联合稀疏性压缩。《信息科学》，640,119095。

王、X.、张 K.、王 J.、金 Y.（2021）。一款增强型竞争性群体优化器，具有强大稀疏算子，用于大规模多目标优化。IEEE《进化计算汇刊》，26（5），859 - 871。

王志 - 斐宇、李志（2023b）。关于进化多重搜索等政的调查目标优化算法。应用科学，13（7），4643。

王志 - J.，展志 - H.，光 S.，金浩，张，J.（2020）。自适应粒度学习，分布式粒子群优化，用于大规模优化。IEEE《控制论汇报》，51（3），1175-1188。

王志志、展志浩、林永、余伟志、王浩、光志、张志（2019）。多模优化问题中的自动生态位微分演化与轮廓预测方法。《IEEE 进化计算汇刊》，24（1），114 - 128。

吴宇、杨宇、陈宇、田宇、唐宇（2023）。针对大规模多目标优化问题的有向快速搜索引导进化算法。载于《遗传与进化计算会议论文集》（第 777 - 785 页）。

徐宇、徐正、张浩、黄宇、刘宇、野岛宇、曾宇（2022）。多重 —— 总体多目标进化算法基于决策变量对大规模多目标优化目标的贡献。IEEE 控制论汇刊，53（11），6998 - 7007。

薛斌、张荣、布朗 W. N.（2013）。特征粒子群优化分类中的选择：多目标方法。《IEEE 控制论汇刊》，43（6），1656 - 1671。

杨晓、邹、杨志、郑志、刘耀（2021）。一个用于大规模多目标优化的模糊决策变量框架。《IEEE 进化计算汇刊》，27（3），445 - 459。

张宇、王启、李伟、张宇（2023a）。基于三群体的协作进化算法，用于大规模多目标优化。《专家系统与应用》，227,120290。

张宇、田宇、张宇（2023b）。改进了针对稀疏大规模多目标优化问题的稀疏 EA。《复杂与智能系统》，9（2），1127 - 1142。

张宇、吕宇、田宇、张宇（2024）。基于稀疏聚类用于稀疏大规模多目标优化。《人工智能工程应用》，133 卷，108194。赵 F.、周 G.、王 L.（2023）。带强化的协作散射搜索分布式置换流车调度问题的学习机制。使用序列依赖的设置时间。IEEE 系统、人类与网络电子学的行动：系统，53（8），4899 - 4912。

齐茨勒，E.，和蒂勒，L.（1999）。多目标进化算法：比较情况学习和力量，采用帕雷托方法。IEEE 进化计算的行动，3（4），257 - 271。

邹、刘、Y.、邹、杨 S.、郑 J.（2023）。一种基于动态稀疏分组的进化算法，用于稀疏大规模多目标优化。信息 tionSciences，631，449 - 467。